

| <pre>!pip install -q requests torch bitsandbytes transformers sentencepiece accelerate  from google.colab import userdata from huggingface_hub import login from transformers import AutoTokenizer, AutoModelForCausalLM, TextStreamer, BitsAndBytesConfig import torch</pre> |                                                                                                                                                      |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------|
| Hàm/Dòng lệnh                                                                                                                                                                                                                                                                 | Chức năng                                                                                                                                            |
| <pre>!pip install -q requests torch bitsandbytes transformers sentencepiece accelerate</pre>                                                                                                                                                                                  | Cài đặt các thư viện cần thiết một cách yên lặng (-q để tắt thông báo).                                                                              |
| <pre>from google.colab import userdata</pre>                                                                                                                                                                                                                                  | Nhập module userdata từ Google Colab để làm việc với thông tin người dùng.                                                                           |
| <pre>from huggingface_hub import login</pre>                                                                                                                                                                                                                                  | Nhập hàm login để đăng nhập vào Hugging Face Hub.                                                                                                    |
| <pre>from transformers import AutoTokenizer, AutoModelForCausalLM, TextStreamer, BitsAndBytesConfig</pre>                                                                                                                                                                     | Nhập các thành phần từ thư viện Transformers: tokenizer tự động, mô hình ngôn ngữ nhân tạo, trình phát trực tuyến văn bản, và cấu hình BitsAndBytes. |
| <pre>import torch</pre>                                                                                                                                                                                                                                                       | Nhập thư viện PyTorch để xử lý tensor và chạy mô hình AI.                                                                                            |

| <pre>login('hf_gVjArVVeOiNjuWwiSnyHLExAdZyASYgGP', add_to_git_credential=True)  LLAMA = "mistralai/Mistral-7B-v0.1" PHI3 = "microsoft/Phi-3-mini-4k-instruct" GEMMA2 = "google/gemma-2-2b-it" QWEN2 = "Qwen/Qwen2-7B-Instruct" # exercise for you MIXTRAL = "mistralai/Mixtral-8x7B-Instruct-v0.1" # If this doesn't fit it your GPU memory, try others from the hub  messages = [     {"role": "system", "content": "You are a helpful assistant"},     {"role": "user", "content": "Tell a light-hearted joke for a room of Data Scientists"} ]</pre> |                                                                                       |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
| Hàm/Dòng lệnh                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           | Chức năng                                                                             |
| <pre>login('hf_gVjArVVeOiNjuWwi snyHLExAdZyASYgGP', add_to_git_credential=True)</pre>                                                                                                                                                                                                                                                                                                                                                                                                                                                                   | Đăng nhập vào Hugging Face bằng token, đồng thời lưu thông tin vào Git credentials.   |
| <pre>LLAMA = "mistralai/Mistral- 7B-v0.1"</pre>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         | Định nghĩa tên mô hình Mistral-7B-v0.1.                                               |
| <pre>PHI3 = "microsoft/Phi-3-mini- 4k-instruct"</pre>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   | Định nghĩa tên mô hình Phi-3-mini-4k-instruct.                                        |
| <pre>GEMMA2 = "google/gemma-2- 2b-it"</pre>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             | Định nghĩa tên mô hình Gemma-2-2B.                                                    |
| <pre>QWEN2 = "Qwen/Qwen2-7B- Instruct"</pre>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            | Định nghĩa tên mô hình Qwen2-7B-Instruct.                                             |
| <pre>MIXTRAL = "mistralai/Mixtral-8x7B- "</pre>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         | Định nghĩa tên mô hình Mixtral-8x7B-Instruct-v0.1 với cảnh báo về yêu cầu bộ nhớ GPU. |

|                  |                                                                                                                                     |
|------------------|-------------------------------------------------------------------------------------------------------------------------------------|
| Instruct-v0.1"   |                                                                                                                                     |
| messages = [...] | Khởi tạo danh sách tin nhắn cho mô hình hội thoại, bao gồm một tin nhắn hệ thống và một tin nhắn người dùng yêu cầu kể chuyện cười. |

```
# Quantization Config - this allows us to load the model into memory and use less memory
```

```
quant_config = BitsAndBytesConfig(
    load_in_4bit=True,
    bnb_4bit_use_double_quant=True,
    bnb_4bit_compute_dtype=torch.bfloat16,
    bnb_4bit_quant_type="nf4"
)
```

```
# Tokenizer
```

```
tokenizer = AutoTokenizer.from_pretrained(LLAMA)
```

```
tokenizer.pad_token = tokenizer.eos_token
```

```
inputs = tokenizer.apply_chat_template(messages, return_tensors="pt",
chat_template="llama-2").to("cuda")
```

```
# The model
```

```
model = AutoModelForCausalLM.from_pretrained(LLAMA, device_map="auto",
quantization_config=quant_config)
```

| Hàm/Dòng lệnh                                     | Chức năng                                                                                                                              |
|---------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------|
| quant_config = BitsAndBytesConfig(...)            | Cấu hình lượng tử hóa (Quantization Config) để tải mô hình vào bộ nhớ với dung lượng nhỏ hơn.                                          |
| tokenizer = AutoTokenizer.from_pretrained(LLAMA)  | Tải tokenizer từ mô hình LLAMA.                                                                                                        |
| tokenizer.pad_token = tokenizer.eos_token         | Đặt token đệm (pad_token) bằng token kết thúc (eos token).                                                                             |
| inputs = tokenizer.apply_chat_template(...)       | Áp dụng mẫu hội thoại (chat_template="llama-2") và chuyển đổi dữ liệu sang tensor PyTorch trên GPU (to("cuda")).                       |
| model = AutoModelForCausalLM.from_pretrained(...) | Tải mô hình LLAMA với bản đồ thiết bị tự động (device_map="auto") và sử dụng cấu hình lượng tử hóa (quantization_config=quant_config). |

```
memory = model.get_memory_footprint() / 1e6
print(f"Memory footprint: {memory:,.1f} MB")

model
```

```
outputs = model.generate(inputs, max_new_tokens=80)
print(tokenizer.decode(outputs[0]))
```

| Hàm/Dòng lệnh | Chức năng                                         |
|---------------|---------------------------------------------------|
| memory        | Tính toán lượng bộ nhớ mà mô hình sử dụng (đơn vị |

|                                                     |                                                                              |
|-----------------------------------------------------|------------------------------------------------------------------------------|
| model.get_memory_footprint() / 1e6                  | MB).                                                                         |
| print(f"Memory footprint: {memory:,.1f} MB")        | In ra dung lượng bộ nhớ mô hình sử dụng.                                     |
| model                                               | Hiển thị thông tin về mô hình đã tải.                                        |
| outputs = model.generate(inputs, max_new_tokens=80) | Sinh văn bản đầu ra dựa trên đầu vào (inputs), giới hạn tối đa 80 token mới. |
| print(tokenizer.decode(outputs[0]))                 | Giải mã và in kết quả văn bản đầu ra.                                        |

```

del inputs, outputs, model
torch.cuda.empty_cache()

def generate(model, messages):
    tokenizer = AutoTokenizer.from_pretrained(model)
    tokenizer.pad_token = tokenizer.eos_token
    inputs = tokenizer.apply_chat_template(messages, return_tensors="pt",
add_generation_prompt=True).to("cuda")
    streamer = TextStreamer(tokenizer)
    model = AutoModelForCausalLM.from_pretrained(model, device_map="auto",
quantization_config=quant_config)
    outputs = model.generate(inputs, max_new_tokens=80, streamer=streamer)
    del tokenizer, streamer, model, inputs, outputs
    torch.cuda.empty_cache()

```

| Hàm/Dòng lệnh                                                                                                | Chức năng                                                                                                 |
|--------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| del inputs, outputs, model                                                                                   | Giải phóng bộ nhớ bằng cách xóa các biến không cần thiết.                                                 |
| torch.cuda.empty_cache()                                                                                     | Dọn dẹp bộ nhớ cache của GPU để tối ưu hóa tài nguyên.                                                    |
| def generate(model, messages):                                                                               | Định nghĩa hàm generate để sinh văn bản từ mô hình.                                                       |
| tokenizer = AutoTokenizer.from_pretrained(model)                                                             | Tải tokenizer tương ứng với mô hình.                                                                      |
| tokenizer.pad_token = tokenizer.eos_token                                                                    | Đặt token padding là token kết thúc (eos_token).                                                          |
| inputs = tokenizer.apply_chat_template(messages, return_tensors="pt", add_generation_prompt=True).to("cuda") | Chuyển đổi danh sách tin nhắn thành tensor PyTorch để đưa vào mô hình, sử dụng GPU.                       |
| streamer = TextStreamer(tokenizer)                                                                           | Tạo streamer để hiển thị kết quả đầu ra theo thời gian thực.                                              |
| model = AutoModelForCausalLM.from_pretrained(model, device_map="auto", quantization_config=quant_config)     | Tải mô hình với cấu hình định lượng (quantization_config) và tự động ánh xạ thiết bị (device_map="auto"). |
| outputs = model.generate(inputs, max_new_tokens=80, streamer=streamer)                                       | Sinh văn bản đầu ra với tối đa 80 token mới và hiển thị trực tiếp qua streamer.                           |

|                                                 |                                                           |
|-------------------------------------------------|-----------------------------------------------------------|
| streamer=streamer)                              |                                                           |
| del tokenizer, streamer, model, inputs, outputs | Giải phóng bộ nhớ bằng cách xóa các biến sau khi sử dụng. |
| torch.cuda.empty_cache()                        | Dọn dẹp bộ nhớ cache của GPU để giải phóng tài nguyên.    |

| <pre> messages = [     {"role": "user", "content": "Tell a light-hearted joke for a room of Data Scientists"} ]  generate(PHI3, messages) </pre> |                                                                                                           |
|--------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| Hàm/Dòng lệnh                                                                                                                                    | Chức năng                                                                                                 |
| messages = [{"role": "user", "content": "Tell a light-hearted joke for a room of Data Scientists"}]                                              | Tạo danh sách tin nhắn đầu vào, trong đó người dùng yêu cầu một câu chuyện cười dành cho Data Scientists. |
| generate(PHI3, messages)                                                                                                                         | Gọi hàm generate để sinh văn bản sử dụng mô hình PHI3 và danh sách tin nhắn đã định nghĩa.                |