


13. Day 4 - Hugging Face Model Class Running Inference on Open-Source AI Models.mp4 - Chương trình VLC

Tập tin Chế Độ Phát Audio Video Phụ đề Công cụ Chế độ hiển thị Trợ giúp

Do you want to restart the playback where left off?



WEEK 3 DAY 3

Time for the model

What you can now do

- Confidently code with Frontier Models
- Build a multi-modal AI Assistant with Tools
- Use HuggingFace pipelines and tokenizers

After today you will have essential new skills

- Work with HuggingFace lower level APIs
- Use HuggingFace models to generate text
- Compare the results across 5 open source models


So what can you already do?

00:27

Giới thiệu về tuần 3, ngày 4:
Chào mừng người xem và giới thiệu chủ đề về việc chạy inference trên các mô hình mã nguồn mở.
Các API của Hugging Face: Trình bày về các API cao cấp và thấp cấp của Hugging Face, bắt đầu từ Tokenizers và chuyển sang mô hình.
Khả năng sử dụng mô hình: Cung cấp thông tin về các khả năng sử dụng mô hình Hugging Face, bao gồm xây dựng AI đa phương thức và sử dụng pipelines, tokenizers.
Giới thiệu các mô hình: Giới thiệu các mô hình sử dụng trong video: Llama 3.1, Phi 3, Gemma, Mistral và Quinn 2.

13. Day 4 - Hugging Face Model Class Running Inference on Open-Source AI Models.mp4 - Chương trình VLC

Tập tin Chế Độ Phát Audio Video Phụ đề Công cụ Chế độ hiển thị Trợ giúp



We will use these models

We will try Llama 3.1, Phi and Gemma, and you should try Mixtral and Qwen2

Llama 3
Llama 3.1 from Meta

Phi-3
Phi 3 from Microsoft

Gemma
Gemma from Google

Mixtral
Mixtral from Mistral

Qwen 2
Qwen 2 from Alibaba Cloud

01:52

Giới thiệu các mô hình mà người xem sẽ làm quen, với một số mô hình để người xem tự thử nghiệm.

Đề cập đến ba kỹ thuật quan trọng khi làm việc với mô hình nguồn mở: quantization, kiểm tra bên trong mô hình, và streaming kết quả.

13. Day 4 - Hugging Face Model Class Running Inference on Open-Source AI Models.mp4 - Chương trình VLC

Tập tin Chế Độ Phát Audio Video Phụ đề Công cụ Chế độ hiển thị Trợ giúp

We will also cover...



Quantization Model Internals Streaming

03:25

Quản lý và cải tiến mô hình: Giải thích kỹ thuật quantization (giảm độ chính xác trọng số mô hình) và tầm quan trọng của nó khi sử dụng mô hình trên các GPU thấp cấp.

Khám phá lớp PyTorch trong Hugging Face: Thảo luận về cấu trúc lớp PyTorch trong mô hình Hugging Face.

Streaming kết quả: Hướng dẫn cách stream kết quả khi làm việc với các mô hình nguồn mở.

Kết thúc và bắt đầu thực hành: Khuyến khích người xem bắt đầu thực hành thay vì chỉ nghe lý thuyết.

14. Day 4 - Hugging Face Transformers Loading & Quantizing LLMs with Bits & Bytes.mp4 - Chương trình VLC

Tập tin Chế Độ Phát Audio Video Phụ đề Công cụ Chế độ hiển thị Trợ giúp

models.ipynb

```
[1] !pip install -q requests torch bitsandbytes transformers sentencepiece accelerate
```

```
from google.colab import userdata
from huggingface_hub import login
from transformers import AutoTokenizer, AutoModelForCausalLM, TextStreamer, BitsAndBytesConfig
import torch
```

Sign in to Hugging Face

1. If you haven't already done so, create a free HuggingFace account at <https://huggingface.co> and navigate to Settings, then Create a new API token, giving yourself write permissions
2. Press the "key" icon on the side panel to the left, and add a new secret: HF_TOKEN = your_token
3. Execute the cell below to log in.

```
hf_token = userdata.get('HF_TOKEN')
login(hf_token, add_to_git_credential=True)
```

```
# instruct models

LLAMA = "meta-llama/Meta-Llama-3.1-8B-Instruct"
PHI3 = "microsoft/Phi-3-mini-4k-instruct"
GEMMA2 = "google/gemma-2-2b-it"
QWEN2 = "Qwen/Qwen2-7B-Instruct" # exercise for you
MISTRAL = "mistralai/Mistral-8x7B-Instruct-v0.1" # If this doesn't fit it your GPU memory, try others from the hub
```

```
messages = [
```

00:11

Cài đặt môi trường và sử dụng Hugging Face:

- Video này phù hợp với các video hướng dẫn về cài đặt và sử dụng môi trường Google Colab, Hugging Face, và các thư viện liên quan đến mô hình học sâu.

Giới thiệu và thực hành với quantization:

- Phù hợp với các video giải thích kỹ thuật quantization, cách giảm độ chính xác của mô hình để tiết kiệm bộ nhớ và tăng hiệu suất.

Tạo và sử dụng mô hình học sâu:

- Thích hợp cho video về cách tạo và sử dụng mô hình học sâu, đặc biệt là các mô hình dựa trên PyTorch và cách tối ưu hóa bộ nhớ khi làm việc với các mô hình lớn.

Thực hành và kiểm tra mô hình:

- Phù hợp cho video về việc kiểm tra và kiểm soát mô hình sau khi tải về và sử dụng, bao gồm kiểm tra bộ nhớ và hiệu suất mô hình.

15. Day 4 - Hugging Face Transformers Generating Jokes with Open-Source AI Models.mp4 - Chương trình VLC

Tập tin Chế Độ Phát Audio Video Phụ đề Công cụ Chế độ hiển thị Trợ giúp

models.ipynb - Colab

colab.research.google.com/drive/1hR9Z-yiqUe7pJjVQW4c74z_V3VchLy#scrollTo=PQgmAD5ZtqWA

models.ipynb

File Edit View Insert Runtime Tools Help All changes saved

+ Code + Text

```
LlamaForCausalLM(
  (model): LlamaModel(
    (embed_tokens): Embedding(128256, 4096)
    (layers): ModuleList(
      (0-31): 32 x LlamaDecoderLayer(
        (self_attn): LlamaSdpaAttention(
          (q_proj): Linear4bit(in_features=4096, out_features=4096, bias=False)
          (k_proj): Linear4bit(in_features=4096, out_features=1024, bias=False)
          (v_proj): Linear4bit(in_features=4096, out_features=1024, bias=False)
          (o_proj): Linear4bit(in_features=4096, out_features=4096, bias=False)
          (rotary_emb): LlamaRotaryEmbedding()
        )
        (mlp): LlamaMLP(
          (gate_proj): Linear4bit(in_features=4096, out_features=14336, bias=False)
          (up_proj): Linear4bit(in_features=4096, out_features=14336, bias=False)
          (down_proj): Linear4bit(in_features=14336, out_features=4096, bias=False)
          (act_fn): SiLU()
        )
        (input_layernorm): LlamaRMSNorm((4096,), eps=1e-05)
        (post_attention_layernorm): LlamaRMSNorm((4096,), eps=1e-05)
      )
    )
    (norm): LlamaRMSNorm((4096,), eps=1e-05)
    (rotary_emb): LlamaRotaryEmbedding()
  )
  (lm_head): Linear(in_features=4096, out_features=128256, bias=False)
)

[ ] outputs = model.generate(inputs, max_new_tokens=80)
print(tokenizer.decode(outputs[0]))

[ ] # Clean up
del inputs, outputs
torch.cuda.empty_cache()
```

And welcome back to us continuing our journey through the model class in Hugging Face Transformers library.


00:02

0s completed at 7:39 PM

Video hướng dẫn kỹ thuật về Hugging Face Transformers: Dành cho những ai muốn tìm hiểu cách sử dụng các mô hình học sâu như Llama 3.1, Phi 3 và Gemma trong việc tạo ra văn bản hoặc trả lời câu hỏi tự động. Video về lập trình và tối ưu hóa bộ nhớ: Giải thích về cách tối ưu hóa bộ nhớ khi làm việc với các mô hình AI lớn.

16. Day 4 - Mastering Hugging Face Transformers Models, Pipelines, and Tokenizers.mp4 - Chương trình VLC

Tập tin Chế Độ Phát Audio Video Phụ đề Công cụ Chế độ hiển thị Trợ giúp



WEEK 3 DAY 4

Practice, practice, practice

What you can now do

- Confidently code with Frontier Models
- Build a multi-modal AI Assistant with Tools
- Use HuggingFace pipelines, tokenizers and models

After the next session you will be experienced with models

- Confidently work with tokenizers and models
- Run inference on open-source models
- Implement an LLM solution combining Frontier and open-source models

And it will be a useful business application.

01:19

Chuyên đề về Hugging Face Transformers: Video này phù hợp với khóa học hoặc hướng dẫn dành cho những người học về thư viện Hugging Face Transformers và việc áp dụng nó vào các dự án thực tế, như tạo mô hình AI và triển khai các ứng dụng kinh doanh.

Dự án thực tế và ứng dụng AI: Nội dung của video cũng liên quan đến việc xây dựng và triển khai các giải pháp AI trong doanh nghiệp, vì vậy nó có thể là một phần của chuỗi học tập về xây dựng AI hoặc phát triển sản phẩm với AI.