



WEEK 6


Now it gets real: from inference to TRAINING

What you can now do

- Generate text and code with Frontier Models including AI Assistants with Tools, and with open-source models with HuggingFace transformers
- Confidently choose the right LLM for your project, backed by metrics
- Create advanced RAG solutions with LangChain

Today we start on the major project; very shortly you'll be able to

- Download a Dataset from the HuggingFace hub
- Examine a dataset
- Identify evaluation criteria for judging success



Chuyển từ suy luận (Inference) sang huấn luyện (Training)

- **Trước đây:** Đã tập trung vào suy luận (inference), tức là sử dụng mô hình đã huấn luyện để dự đoán đầu ra từ một đầu vào.
- **Bây giờ:** Bắt đầu tìm hiểu về cách huấn luyện mô hình để cải thiện hiệu suất suy luận.

Các nội dung chính:

1. **Tầm quan trọng của dữ liệu:**
 - Việc tạo và xử lý tập dữ liệu là một phần quan trọng của quá trình huấn luyện.
 - Sẽ tìm hiểu cách hiểu rõ dữ liệu, trực quan hóa, làm sạch và chuẩn bị dữ liệu tốt nhất có thể.
2. **Cách đánh giá thành công:**
 - Xác định tiêu chí đánh giá kết quả của dự án.
 - Hiểu rõ mục tiêu và cách đo lường xem mô hình có đạt được kỳ vọng hay không.
3. **Những gì sẽ thực hiện:**
 - Tải tập dữ liệu từ Hugging Face.
 - Kiểm tra, phân tích và xử lý tập dữ liệu.
 - Xác định tiêu chí đánh giá hiệu suất mô hình.

Tóm tắt nội dung khóa học 8 tuần về LLM Engineering

Khóa học kéo dài 8 tuần nhằm giúp người học trở thành một **LLM Engineer**. Dưới đây là các nội dung chính được học qua từng tuần:

1. **Tuần 1:** Giới thiệu về các mô hình tiên tiến (Frontier Models) và trải nghiệm sử dụng chúng.
2. **Tuần 2:** Làm việc với nhiều API khác nhau, xây dựng giao diện với **Gradio**, tích hợp đa phương thức (Multi-modality).
3. **Tuần 3:** Khám phá **Hugging Face**, bao gồm **Pipelines, Tokenizers và Models**.
4. **Tuần 4:** Lựa chọn mô hình phù hợp, sử dụng mô hình để **tạo mã (Code Generation)** và tối ưu hóa mã nhanh gấp **60,000 lần**.
5. **Tuần 5:** Tìm hiểu về **Retrieval-Augmented Generation (RAG)** – một chủ đề đang rất hot.
6. **Tuần 6:** **Fine-tuning một mô hình Frontier**, tập trung vào huấn luyện mô hình.
7. **Tuần 7:** Fine-tuning mô hình **mã nguồn mở**, về cơ bản là tự xây dựng mô hình của riêng mình.
8. **Tuần 8:** Tổng hợp tất cả kiến thức để **làm chủ LLM Engineering**.


Mục tiêu cuối cùng:

Sau 8 tuần, học viên có thể **tin chính, tối ưu và triển khai mô hình LLM**, trở thành một **LLM Engineer chuyên nghiệp**




So far we have focused exclusively on INFERENCE

Techniques to improve results at run-time with Closed and Open-Source models




Multi-shot prompting



Prompt Chaining




Tools / Function calling



RAG / Knowledge Base

This week we turn to TRAINING



- Training a multi-billion parameter model from scratch would cost tens to hundreds of million \$
- Instead, we take advantage of **Transfer Learning**
- We take a pretrained model as base, and use additional training data to fine-tune it for our task

Tóm tắt nội dung đã học và chuyển đổi từ suy luận sang huấn luyện mô hình

1. Nội dung đã học về suy luận (Inference)

Trong giai đoạn suy luận, khóa học tập trung vào các kỹ thuật cải thiện hiệu suất của mô hình có sẵn mà không cần huấn luyện lại. Cụ thể:

- **Multi-shot prompting:** Cung cấp nhiều ví dụ để mô hình hiểu rõ hơn.
- **Prompt Chaining:** Chuỗi lời nhắc (prompts) liên kết với nhau, xây dựng và tổng hợp kết quả.
- **Tools / Function Calling:** Kết hợp mô hình với các công cụ bên ngoài để thực hiện các tác vụ như tính giá vé máy bay, v.v.
- **RAG (Retrieval-Augmented Generation):** Tiêm thêm thông tin phù hợp vào lời nhắc để cải thiện độ chính xác của mô hình.

Các phương pháp này giúp tận dụng mô hình có sẵn mà không cần thay đổi trọng số hoặc cấu trúc mô hình.

2. Chuyển sang giai đoạn huấn luyện (Training)

Sau khi tối ưu hóa suy luận, khóa học bắt đầu chuyển sang huấn luyện mô hình:

- **Huấn luyện giúp điều chỉnh trọng số của mô hình** để dự đoán tốt hơn.
- **Mô hình lớn (LLM) rất tốn kém để huấn luyện từ đầu** (hơn 100 triệu USD).
- **Giải pháp: Transfer Learning và Fine-tuning**
- Sử dụng mô hình đã được huấn luyện sẵn trên dữ liệu lớn.
- Tiếp tục huấn luyện trên một tập dữ liệu cụ thể để tối ưu hóa cho tác vụ mong muốn.
- **Fine-tuning** giúp mô hình trở nên chính xác hơn đối với nhiệm vụ chuyên biệt.
- Kỹ thuật **QLoRA** giúp giảm yêu cầu bộ nhớ trong quá trình fine-tuning.

BUT FIRST, TO INTRODUCE

A juicy commercial problem

Given a description of a product, predict its price

- For a marketplace to estimate prices of goods
- Future versions should be able to write and improve descriptions too
- We'd typically use a Regression model to predict prices, but there are good reasons to try Gen AI

We can train an LLM and evaluate it very clearly

It means we can battle with GPT-4o

Spoiler alert: the frontier models are already great at this!

Bài học giới thiệu về một bài toán thương mại thực tế: **Dự đoán giá của một sản phẩm dựa trên mô tả của nó**. Đây là một bài toán phổ biến trong các nền tảng thương mại điện tử và có thể được giải quyết theo nhiều cách khác nhau:

1. **Bài toán và ứng dụng:**
 - Dành cho các nền tảng thương mại điện tử để ước tính giá của sản phẩm.
 - Hệ thống trong tương lai có thể không chỉ dự đoán giá mà còn viết và cải thiện mô tả sản phẩm.
2. **Phương pháp truyền thống:**
 - Đây thường được coi là một bài toán hồi quy (Regression) vì đầu ra là một con số (giá trị sản phẩm).
 - Hồi quy là phương pháp phổ biến để dự đoán giá trị số.
3. **Lý do thử nghiệm AI tạo sinh (Generative AI):**
 - Mặc dù Generative AI (LLMs) ban đầu được thiết kế để tạo văn bản, nhưng chúng đã thể hiện khả năng ấn tượng trong việc xử lý các bài toán định lượng.
 - Những mô hình AI tiên tiến như GPT có thể trả về kết quả dưới dạng JSON với các giá trị số chính xác.
 - Thậm chí, các mô hình AI tạo sinh có thể làm tốt hơn một số mô hình hồi quy truyền thống.
4. **Tính dễ đánh giá của bài toán:**
 - Bài toán này có thể đo lường hiệu quả một cách đơn giản và trực quan: **so sánh giá trị dự đoán với giá trị thực tế**.
 - Không cần các chỉ số phức tạp như "perplexity" trong xử lý ngôn ngữ tự nhiên.
 - Dễ dàng quan sát được mức độ cải thiện của mô hình.
5. **Hướng đi trong khóa học:**
 - Bắt đầu với mô hình hồi quy để hiểu rõ cách tiếp cận truyền thống.
 - Thử nghiệm với Generative AI để xem liệu nó có thể làm tốt hơn hay không.
 - Tập trung vào dữ liệu trong phần tiếp theo.

Tóm tắt nội dung bài học về tìm kiếm tập dữ liệu (Finding datasets)

Bài học này đề cập đến một phần quan trọng trong quá trình xây dựng mô hình AI: **Tìm kiếm và tạo tập dữ liệu**. Mặc dù đây có thể không phải là phần hấp dẫn nhất, nhưng nó lại cực kỳ quan trọng để đảm bảo chất lượng của mô hình.

Các nguồn tìm kiếm dữ liệu chính:

1. **Dữ liệu nội bộ (Proprietary Data)**
 - Là dữ liệu do công ty sở hữu và có liên quan trực tiếp đến bài toán.
 - Ví dụ: Trong bài toán giá lập RAG, người giảng viên sử dụng dữ liệu từ ổ đĩa chung của công ty để xây dựng cơ sở tri thức.
 - Công ty của giảng viên, Nebula, có dữ liệu về nhân tài và việc làm để huấn luyện mô hình riêng.
2. **Kaggle**
 - Một nguồn dữ liệu rất phổ biến cho cộng đồng khoa học dữ liệu.
 - Có nhiều tập dữ liệu từ nhiều lĩnh vực khác nhau do cộng đồng đóng góp.
3. **Hugging Face Datasets**
 - Một nguồn tài nguyên tuyệt vời với rất nhiều tập dữ liệu phục vụ cho các mô hình AI, đặc biệt là xử lý ngôn ngữ tự nhiên (NLP).
 - Giảng viên cho biết sẽ sử dụng Hugging Face trong phần tiếp theo của khóa học.
4. **Dữ liệu tổng hợp (Synthetic Data)**
 - Được tạo ra bởi mô hình AI thay vì thu thập từ thế giới thực.
 - Trong dự án RAG giả lập, giảng viên đã sử dụng một mô hình ngôn ngữ lớn (LLM) để tạo ra dữ liệu tổng hợp.
 - Lưu ý:
 - Không nên sử dụng mô hình AI để tạo dữ liệu rồi lại dùng chính dữ liệu đó để huấn luyện nó (vì dễ gây sai lệch).
 - Tuy nhiên, nếu muốn tạo một mô hình nhỏ hơn, rẻ hơn dựa trên mô hình lớn, có thể sử dụng dữ liệu tổng hợp.
5. **Các công ty chuyên cung cấp dữ liệu**
 - Một số công ty chuyên thu thập và tạo tập dữ liệu tùy chỉnh cho khách hàng.
 - Ví dụ: Công ty **Scale** chuyên xây dựng các bộ dữ liệu chất lượng cao để phục vụ huấn luyện mô hình AI.
- Tóm lại:**

 - Tập dữ liệu là yếu tố quan trọng nhất để huấn luyện mô hình AI.
 - Cần lựa chọn nguồn dữ liệu phù hợp: **dữ liệu nội bộ, Kaggle, Hugging Face, dữ liệu tổng hợp hoặc công ty chuyên biệt**.
 - Trong phần tiếp theo, giảng viên sẽ sử dụng **Hugging Face Datasets** để làm ví dụ.

Finding datasets


Your own proprietary data

Kaggle

HuggingFace datasets




Synthetic data

Specialist companies like Scale.com



- JupyterLab sẽ được sử dụng để thực hiện các bước phân tích dữ liệu.
- Hugging Face Hub sẽ được sử dụng để lưu trữ dữ liệu đã được xử lý.

Mục tiêu: Chuẩn bị dữ liệu cho việc huấn luyện mô hình dự đoán giá sản phẩm.



Phân tích dữ liệu mẫu:

- Xem xét một vài mẫu dữ liệu đầu tiên để hiểu cấu trúc và nội dung của chúng.
- Nhận thấy rằng không phải tất cả các sản phẩm đều có giá (price) được ghi nhận.
- Mô tả (description) được lưu trữ dưới dạng danh sách, trong khi chi tiết (details) được lưu trữ dưới dạng chuỗi JSON.

Kiểm tra số lượng sản phẩm có giá:

- Lập qua tất cả các sản phẩm trong tập dữ liệu để đếm số lượng sản phẩm có giá hợp lệ (giá là số và lớn hơn 0).
- Kết quả cho thấy khoảng 50% sản phẩm trong danh mục đồ gia dụng có giá.

Định dạng số:

- Học cách sử dụng f-strings trong Python để định dạng số với dấu phẩy phân tách hàng nghìn (ví dụ: {:,}), giúp dễ đọc hơn.

Tính toán độ dài văn bản:

- Tính toán tổng số ký tự trong tiêu đề (title), mô tả (description), tính năng (features) và chi tiết (details) của mỗi sản phẩm có giá.
- Lưu trữ độ dài này vào một danh sách (lengths) để phân tích phân phối độ dài văn bản.

Mục tiêu:

- Hiểu rõ hơn về dữ liệu và các vấn đề tiềm ẩn (ví dụ: thiếu giá).
- Chuẩn bị dữ liệu cho các bước phân tích tiếp theo (ví dụ: phân phối độ dài văn bản).

Sử dụng Matplotlib để trực quan hóa dữ liệu:

- Matplotlib được sử dụng để tạo biểu đồ histogram, hiển thị phân phối độ dài văn bản (số ký tự) trong mô tả sản phẩm.
- Biểu đồ này giúp hiểu rõ hơn về phạm vi và phân phối độ dài văn bản.

Phân tích biểu đồ histogram:

- Trục x biểu thị độ dài văn bản (số ký tự).
- Trục y biểu thị số lượng sản phẩm có độ dài văn bản tương ứng.
- Biểu đồ cho thấy có một đỉnh tập trung ở một phạm vi độ dài nhất định, nhưng cũng có một "đuôi dài" (long tail) của các sản phẩm có độ dài văn bản lớn hơn nhiều.

Thách thức trong huấn luyện mô hình:

- Độ dài văn bản lớn có thể gây ra thách thức trong quá trình huấn luyện mô hình, đặc biệt là với các mô hình mã nguồn mở có giới hạn về số lượng token đầu vào.
- Số lượng token đầu vào lớn hơn đòi hỏi nhiều bộ nhớ hơn và làm tăng độ khó của quá trình huấn luyện.
- Ngay cả khi sử dụng các mô hình tiên tiến (frontier models), số lượng token lớn hơn cũng làm tăng chi phí.

Cân nhắc về chi phí và hiệu suất:

- Việc xử lý các sản phẩm có mô tả dài hơn sẽ tốn kém hơn về mặt tài nguyên và chi phí, đặc biệt khi xử lý một lượng lớn dữ liệu.
- Việc xác định một ngưỡng độ dài phù hợp (cutoff) có thể giúp tối ưu hóa hiệu suất và giảm chi phí.

Kế hoạch tiếp theo:

- Cân nhắc việc giới hạn độ dài văn bản để phù hợp với khả năng của mô hình và giảm chi phí.

Phân phối giá cả:

- Phân tích phân phối giá cả của các sản phẩm trong tập dữ liệu.
- Nhận thấy rằng phần lớn sản phẩm có giá thấp, trong khi một số ít sản phẩm có giá rất cao.
- Điều này dẫn đến sự lệch lạc trong phân phối giá cả.

Sự khác biệt giữa trung bình, trung vị và mốt:

- Nhắc lại các khái niệm thống kê về trung bình (mean), trung vị (median) và mốt (mode).
- Giải thích rằng giá trung bình bị ảnh hưởng bởi các sản phẩm có giá cao, làm cho nó cao hơn so với trung vị và mốt.

Thách thức trong quá trình huấn luyện:


- Sự lệch lạc trong phân phối giá cả có thể gây ra thách thức trong quá trình huấn luyện mô hình.
- Mô hình có thể bị ảnh hưởng bởi số lượng lớn các sản phẩm giá rẻ, dẫn đến kết quả không chính xác cho các sản phẩm giá cao.

Tìm hiểu sản phẩm giá cao nhất:

- Tìm kiếm sản phẩm có giá cao nhất trong tập dữ liệu.
- Phát hiện ra rằng đó là một lò vi sóng công nghiệp có giá khoảng 21.000 đô la.
- So sánh với một sản phẩm tương tự trên Amazon có giá khoảng 18.000 đô la.

Chuẩn bị dữ liệu cho quá trình huấn luyện:

- Nhận thức được sự cần thiết phải xử lý sự lộn xộn trong phân phối giá cả để cải thiện hiệu suất của mô hình.
- Bắt đầu quá trình sắp xếp và lọc dữ liệu để tạo ra một tập dữ liệu phù hợp hơn cho việc huấn luyện.



Sắp xếp dữ liệu:

- Thời điểm đã đến để sắp xếp tập dữ liệu.
- Mỗi điểm dữ liệu từ Hugging Face sẽ được chuyển đổi thành một đối tượng Python, một lớp gọi là "item".
- Lớp "item" được định nghĩa trong một mô-đun riêng biệt (items.py) để có thể tái sử dụng và giữ cho Jupyter notebook gọn gàng.

Mô-đun items.py:

- Chứa mã để xử lý và làm sạch dữ liệu.
- Định nghĩa một lớp "item" với các thuộc tính như tiêu đề (title), giá (price), danh mục (category), số lượng token (token count) và prompt.
- Sử dụng tokenizer của mô hình Llama 3 18B để tính toán số lượng token trong prompt.
- Làm sạch các thông tin nhiễu từ dữ liệu.

Giới hạn số lượng token:

- Tập dữ liệu sẽ được tạo sao cho phù hợp với một số lượng token tối đa nhất định cho tokenizer Llama.
- Điều này giúp tiết kiệm chi phí và làm cho việc huấn luyện dễ dàng hơn, đặc biệt là khi sử dụng mô hình mã nguồn mở.
- Đảm bảo rằng cả mô hình tiên tiến (frontier model) và mô hình mã nguồn mở đều nhận được lượng thông tin tương đương.

Làm sạch dữ liệu:

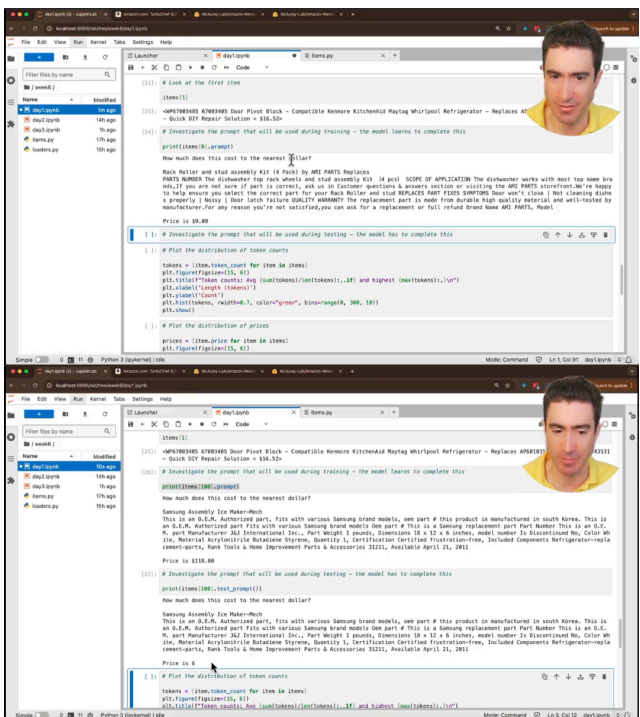
- Sử dụng hàm "scrub details" để loại bỏ các thông tin nhiễu như "batteries included" hoặc "manufacturer".
- Sử dụng hàm "scrub" để loại bỏ các ký tự lạ và thay thế nhiều khoảng trắng bằng một khoảng trắng.
- Loại bỏ các từ có 8 ký tự trở lên và chứa số (có thể là mã phụ tùng) vì chúng không liên quan và chiếm nhiều token.

Tạo prompt:

- Hàm "parse" sẽ tạo ra một prompt từ mỗi điểm dữ liệu.
- Prompt này sẽ được sử dụng để huấn luyện và kiểm tra mô hình.
- Có hai loại prompt: prompt huấn luyện (chứa câu trả lời) và prompt kiểm tra (không chứa câu trả lời).

Mục tiêu:

- Tạo ra một tập dữ liệu chất lượng cao, phù hợp cho việc huấn luyện mô hình dự đoán giá sản phẩm.
- Tối ưu hóa dữ liệu để giảm chi phí và cải thiện hiệu suất của mô hình.
- Hiểu rõ hơn về dữ liệu và các vấn đề tiềm ẩn.



Tạo đối tượng "item" cho dữ liệu có giá:

- Mã được thực thi để tạo đối tượng "item" cho tất cả các sản phẩm trong tập dữ liệu có giá.
- Quá trình này bao gồm làm sạch dữ liệu (loại bỏ mã phụ tùng, thay thế ký tự lạ), tạo prompt và đảm bảo prompt có số lượng token phù hợp.

Kiểm tra dữ liệu đã xử lý:

- Kiểm tra một vài đối tượng "item" đầu tiên để xem dữ liệu đã được xử lý như thế nào.
- Nhận thấy rằng mã phụ tùng đã được loại bỏ khỏi mô tả.
- Thấy rằng mô tả đã được cắt ngắn để phù hợp với giới hạn token.

Xem xét prompt huấn luyện:



- Xem xét prompt huấn luyện cho một sản phẩm cụ thể.
- Prompt bao gồm câu hỏi "How much does this cost to the nearest dollar?" và mô tả sản phẩm.
- Mô tả sản phẩm đã được cắt ngắn để phù hợp với giới hạn token.

Xem xét prompt kiểm tra:

- Xem xét prompt kiểm tra cho cùng một sản phẩm.
- Prompt kiểm tra giống với prompt huấn luyện, nhưng không bao gồm giá sản phẩm.
- Mục đích là để xem liệu mô hình có thể dự đoán giá chính xác dựa trên mô tả sản phẩm hay không.

Mục tiêu:

- Tạo ra một tập dữ liệu phù hợp cho việc huấn luyện và kiểm tra mô hình.
- Hiểu cách dữ liệu được xử lý và định dạng thành prompt.
- Chuẩn bị cho các bước tiếp theo trong quá trình huấn luyện mô hình.



Phân tích số lượng token:

- Biểu đồ được tạo để hiển thị phân phối số lượng token trong các mục đã chọn.
- Số lượng token tối đa là 178, và trung bình là 176, cho thấy dữ liệu được "crammed" (nhồi nhét) để phù hợp với giới hạn.
- Việc giữ số lượng token dưới 180 giúp giảm chi phí và đơn giản hóa quá trình huấn luyện.

Phân tích phân phối giá cả (sau khi lọc):

- Biểu đồ được tạo để hiển thị phân phối giá cả của các mặt hàng đã chọn.
- Giá trung bình là \$100, và giá cao nhất là gần \$11,000.
- Sản phẩm lò vi sóng siêu đắt đã bị loại bỏ trong quá trình lọc.
- Phân phối vẫn bị lệch về phía các mặt hàng giá rẻ.

Trực quan hóa dữ liệu với Matplotlib:

- Nhấn mạnh tầm quan trọng của việc trực quan hóa dữ liệu và sử dụng các tính năng của Matplotlib.
- Cung cấp liên kết đến trang màu Matplotlib để khám phá các bảng màu khác nhau.

Bài tập:


- Khuyến khích xem xét kỹ lớp "item" và các hàm xử lý dữ liệu.
- Sử dụng JupyterLab để kiểm tra và hiểu cách dữ liệu được làm sạch và định dạng.
- Hiểu cách dữ liệu được chuyển đổi thành các prompt huấn luyện và kiểm tra với khoảng 180 token mô tả chi tiết cho mỗi mục.

Chuẩn bị cho bước tiếp theo:

- Bước tiếp theo sẽ mở rộng tập dữ liệu để bao gồm nhiều loại sản phẩm hơn.
- Tập dữ liệu lớn hơn nhiều so với tập dữ liệu hiện tại.

Mục tiêu:

- Hiểu rõ hơn về các đặc điểm của tập dữ liệu đã được xử lý.
- Nắm vững các kỹ thuật trực quan hóa dữ liệu với Matplotlib.
- Chuẩn bị cho việc mở rộng tập dữ liệu và huấn luyện mô hình trên một lượng dữ liệu lớn hơn.



Tầm quan trọng của chất lượng dữ liệu:

- Nhấn mạnh rằng việc cải thiện chất lượng dữ liệu đầu vào là cách hiệu quả nhất để nâng cao hiệu suất của mô hình.
- So sánh với việc điều chỉnh siêu tham số, là một quá trình tốn thời gian nhưng hiệu quả thường không đáng kể.
- Khuyến khích kiểm tra kỹ lưỡng mã làm sạch dữ liệu để đảm bảo không loại bỏ thông tin quan trọng.

Đánh giá hiệu suất mô hình:


- Giới thiệu hai loại chỉ số đánh giá: chỉ số tập trung vào mô hình (model-centric) và chỉ số tập trung vào kết quả kinh doanh (business-centric).
- Chỉ số tập trung vào mô hình đo lường hiệu suất toán học của mô hình (ví dụ: loss huấn luyện, loss kiểm tra, RMSE).
- Chỉ số tập trung vào kết quả kinh doanh đo lường mức độ ảnh hưởng của mô hình đến mục tiêu kinh doanh (ví dụ: sai số giá trung bình, sai số giá theo phần trăm, tỷ lệ dự đoán "tốt").

Các chỉ số cụ thể:

- **Loss huấn luyện và loss kiểm tra:** Đo lường sai số của mô hình trên tập huấn luyện và tập kiểm tra.
- **RMSE (Root Mean Squared Log Error):** Một chỉ số cân bằng giữa sai số tuyệt đối và sai số tương đối, phù hợp cho bài toán dự đoán giá.
- **MSE (Mean Squared Error):** Sai số bình phương trung bình, nhưng có thể bị ảnh hưởng lớn bởi các dự đoán sai lệch lớn.
- **Sai số giá trung bình:** Sai số tuyệt đối trung bình giữa giá dự đoán và giá thực tế, dễ hiểu và phù hợp với mục tiêu kinh doanh.
- **Sai số giá theo phần trăm:** Sai số tương đối giữa giá dự đoán và giá thực tế, phù hợp cho các sản phẩm có giá cao.
- **Tỷ lệ dự đoán "tốt":** Tỷ lệ dự đoán đáp ứng một tiêu chí nhất định về sai số tuyệt đối và/hoặc sai số tương đối.

Mục tiêu:

- Hiểu rõ các phương pháp đánh giá hiệu suất mô hình.
- Lựa chọn các chỉ số phù hợp để đo lường hiệu quả của mô hình dự đoán giá sản phẩm.
- So sánh hiệu suất của các mô hình khác nhau (mô hình tiên tiến và mô hình mã nguồn mở).



Chuẩn bị cho việc lập trình:

- Sắp sửa bắt đầu lập trình và đánh giá hiệu suất của mô hình dự đoán giá.
- Cần thực hiện một số công việc chuẩn bị trước khi bắt đầu.

Chiến lược giải quyết vấn đề:

- Thảo luận về chiến lược kinh doanh để giải quyết vấn đề.
- Nhấn mạnh tầm quan trọng của việc hiểu rõ ngữ cảnh trước khi bắt đầu lập trình.

So sánh các kỹ thuật cải thiện hiệu suất:

- So sánh các kỹ thuật khác nhau để cải thiện hiệu suất mô hình.
- Giải thích sự khác biệt giữa Rag (Retrieval-Augmented Generation) và fine-tuning (tinh chỉnh).
- Làm rõ trường hợp sử dụng phù hợp cho từng kỹ thuật.

Xử lý dữ liệu:

- Cần tiếp tục xử lý dữ liệu và tải lên tập dữ liệu cuối cùng.
- Tập dữ liệu cuối cùng sẽ lớn hơn nhiều so với tập dữ liệu hiện tại.

Nội dung ngày tiếp theo:

- Ngày tiếp theo sẽ bao gồm các nội dung sau:
 - Thảo luận về chiến lược kinh doanh.
 - So sánh các kỹ thuật cải thiện hiệu suất.
 - Xử lý và tải lên tập dữ liệu cuối cùng.

Mục tiêu:

- Hiểu rõ chiến lược giải quyết vấn đề và các kỹ thuật cải thiện hiệu suất.
- Chuẩn bị cho việc lập trình và đánh giá mô hình dự đoán giá.
- Xử lý và chuẩn bị tập dữ liệu cuối cùng cho việc huấn luyện mô hình.