


Day 1

29 Tháng Ba 2025 5:47 CH



TUẦN 4 - NGÀY 1

🔥 **Tuần lễ quan trọng để nâng cao chuyên môn**

Những gì bạn đã có thể làm được:

- ✅ Tự tin lập trình với các Mô hình Frontier
- ✅ Xây dựng Trợ lý AI đa phương thức với Công cụ
- ✅ Phát triển giải pháp với LLM mã nguồn mở bằng **Hugging Face Transformers**

Sau ngày hôm nay, bạn sẽ có thể:

- ♦ Thảo luận về cách lựa chọn LLM phù hợp cho từng tác vụ
- ♦ So sánh các LLM dựa trên thuộc tính cơ bản và các chỉ số đánh giá
- ♦ Sử dụng **Open LLM Leaderboard** để đánh giá mô hình

Lộ trình 8 tuần để thành thạo LLMs 🔥

🚀 **Tuần 1: Khởi đầu với LLMs**

- Hiểu về mô hình ngôn ngữ lớn (LLM)
- Cơ hội và thách thức khi làm việc với LLMs

🤖 **Tuần 2: Mô hình Frontier và Đa phương thức**

- Tương tác với Frontier Models
- Giao diện người dùng (UI) và Agentization
- Ứng dụng đa phương thức trong AI

🔧 **Tuần 3: Mã nguồn mở với Hugging Face**

- Triển khai LLM mã nguồn mở
- Sử dụng **Hugging Face Transformers**

📊 **Tuần 4: Chọn lựa LLMs và Sinh mã**

- Cách chọn mô hình LLM phù hợp
- So sánh LLMs dựa trên thuộc tính và benchmark
- Sử dụng **Open LLM Leaderboard** để đánh giá

💡 **Tuần 5: RAG và Hệ thống Hỏi - Đáp**

- Ứng dụng **RAG (Retrieval-Augmented Generation)**
- Xây dựng hệ thống hỏi - đáp thông minh
- Phát triển trợ lý chuyên gia

🛠️ **Tuần 6: Tinh chỉnh mô hình Frontier**

- Fine-tuning Frontier Models
- Tinh chỉnh mô hình cho bài toán cụ thể

🔧 **Tuần 7: Fine-tuning mô hình mã nguồn mở**

- Tinh chỉnh LLM mã nguồn mở
- Cải thiện độ chính xác và hiệu suất của mô hình

🏆 **Tuần 8: Hoàn thiện - Thành thạo Kỹ sư LLM**

- Tổng hợp kiến thức và thực hành
- Ứng dụng LLM vào các dự án thực tế
- Trở thành **LLM Engineer chuyên nghiệp**



How to compare LLMs

Importantly, LLMs need to be evaluated for suitability for a given task



Start with the basics

- Parameters
- Context length
- Pricing



Then look at the results

- Benchmarks
- Leaderboards
- Arenas

❖ Cách so sánh các mô hình LLM


- ❖ **Quan trọng:** LLMs cần được đánh giá dựa trên mức độ phù hợp với **tác vụ cụ thể**.

1 Bắt đầu với các yếu tố cơ bản

- ❖ **Thông số mô hình (Parameters)** – Số lượng tham số trong mô hình (VD: 7B, 13B, 65B).
- ❖ **Độ dài ngữ cảnh (Context length)** – Số lượng token mô hình có thể xử lý trong một lần.
- ❖ **Chi phí sử dụng (Pricing)** – Mô hình miễn phí hay trả phí, chi phí tính theo API hoặc tự triển khai.

2 Đánh giá kết quả thực tế

- ❖ **Các chỉ số benchmark** – Đánh giá theo chuẩn (VD: MMLU, HellaSwag, GSM8K...).
- ❖ **Bảng xếp hạng (Leaderboards)** – So sánh hiệu suất trên các nền tảng như **Open LLM Leaderboard**.
- ❖ **Thử nghiệm thực tế (Arenas)** – Kiểm tra hiệu suất bằng cách triển khai trên các tác vụ cụ thể.



COMPARING LLMs

The Basics (1)

Compare the following features of an LLM:


- Open-source or closed
- Release date and knowledge cut-off
- Parameters
- Training tokens
- Context length

Tiêu đề:

- ❖ *Comparing LLMs - The Basics (1)*

Các đặc điểm cần so sánh của một LLM:

- ✓ Mã nguồn mở hay đóng (Open-source or closed)
- ✓ Ngày phát hành và giới hạn kiến thức (Release date and knowledge cut-off)
- ✓ Số lượng tham số (Parameters)
- ✓ Số lượng token dùng để huấn luyện (Training tokens)
- ✓ Độ dài ngữ cảnh (Context length)



COMPARING LLMs

The Basics (2)

Compare the following features of an LLM:

- Inference cost
API charge, Subscription or Runtime compute
- Training cost
- Build cost
- Time to Market
- Rate limits
- Speed
- Latency
- License

Các yếu tố quan trọng khi đánh giá LLMs

2 Hiệu suất và Chi phí

- Chi phí suy luận (Inference cost)
- Chi phí huấn luyện (Training cost)
- Chi phí xây dựng (Build cost)
- Thời gian đưa ra thị trường (Time to Market)
- Giới hạn tốc độ (Rate limits)
- Tốc độ phản hồi (Speed & Latency)

3 Mô hình kinh doanh & Cấp phép


- Hình thức tính phí API (API charge, Subscription, or Runtime compute)
- Giấy phép sử dụng (License)

7 common benchmarks that you will often encounter

Benchmark	What's being evaluated	Description
ARC	Reasoning	A benchmark for evaluating scientific reasoning; multiple-choice questions
DROP	Language Comp	Distill details from text then add, count or sort
HellaSwag	Common Sense	"Harder Endings, Long Contexts and Low Shot Activities"
MMLU	Understanding	Factual recall, reasoning and problem solving across 57 subjects
TruthfulQA	Accuracy	Robustness in providing truthful replies in adversarial conditions
Winogrande	Context	Test the LLM understands context and resolves ambiguity
GSM8K	Math	Math and word problems taught in elementary and middle schools

- Chinchilla Scaling:
 - Chinchilla Scaling Law
- Được Google DeepMind đề xuất, mô tả mối quan hệ giữa **số lượng tham số** của mô hình và **kích thước dữ liệu huấn luyện**.
 - Quy tắc tỷ lệ tham số - dữ liệu huấn luyện
- Số tham số **tỷ lệ thuận** với số lượng token trong dữ liệu huấn luyện.
- Nếu **tăng gấp đôi dữ liệu huấn luyện**, thì cũng cần **tăng gấp đôi số tham số** để mô hình có thể khai thác hiệu quả dữ liệu mới.
- Ứng dụng thực tế
 - Một mô hình **8 tỷ tham số** chỉ hiệu quả với một lượng dữ liệu huấn luyện nhất định, nếu vượt quá, hiệu suất không cải thiện đáng kể.
 - Nếu mở rộng mô hình lên **16 tỷ tham số**, cần **gấp đôi dữ liệu huấn luyện** để tối ưu hóa hiệu suất.
- Tính ổn định của luật
 - Luật Chinchilla vẫn **được áp dụng hiệu quả** với các mô hình Transformer hiện nay.
 - Hỗ trợ định hướng **chiến lược mở rộng** trong lĩnh vực AI.

Benchmark	What's being evaluated	Description
ARC	Reasoning	A benchmark for evaluating scientific reasoning; multiple-choice questions
DROP	Language Comp	Distill details from text then add, count or sort
HellaSwag	Common Sense	"Harder Endings, Long Contexts and Low Shot Activities"
MMLU	Understanding	Factual recall, reasoning and problem solving across 57 subjects
TruthfulQA	Accuracy	Robustness in providing truthful replies in adversarial conditions
Winogrande	Context	Test the LLM understands context and resolves ambiguity
GSM8K	Math	Math and word problems taught in elementary and middle schools



COMPARING LLMs

Limitations of Benchmarks

- Not consistently applied
- Too narrow in scope
- Hard to measure nuanced reasoning
- Training data leakage
- Overfitting

And a new concern, not yet proven

- Frontier LLMs may be aware that they are being evaluated

Daemy

🔴 Các Benchmarks phổ biến

1 ARC (AI2 Reasoning Challenge)

- Đánh giá **khả năng suy luận khoa học** của mô hình bằng cách trả lời câu hỏi trắc nghiệm.

2 DROP (Discrete Reasoning Over Paragraphs)

- Kiểm tra **khả năng hiểu ngôn ngữ**, đòi hỏi mô hình đọc văn bản, tổng hợp thông tin, sau đó thực hiện phép tính hoặc sắp xếp dữ liệu.

3 HellaSwag

- Đánh giá **khả năng suy luận thường thức**, tập trung vào **ngữ cảnh dài** và **độ phức tạp cao**.

4 MLU (Massive Multitask Language Understanding)

- Thử nghiệm trên **57 lĩnh vực khác nhau**, giúp kiểm tra khả năng tổng quát của mô hình.
- Tuy nhiên, có tranh cãi về độ chính xác của bài kiểm tra này.

5 MLU Pro

- Phiên bản nâng cấp của MLU, được cho là **đáng tin cậy hơn** so với phiên bản trước.

6 TruthfulQA

- Đánh giá **độ chính xác và tính trung thực** của mô hình, đặc biệt là trong **các tình huống đánh lừa (adversarial settings)**.

7 Winogrande

- Kiểm tra **khả năng xử lý ngữ cảnh phức tạp** và giải quyết **tình huống mơ hồ** trong ngôn ngữ tự nhiên.

8 GSM8K (Grade School Math 8K)

- Đánh giá khả năng **giải toán cấp tiểu học và trung học**, bao gồm cả **bài toán đố có lời văn**.

Hạn chế của Benchmarks trong đánh giá LLMs

🔴 1. Không được áp dụng nhất quán

- Không có **tiêu chuẩn vàng** chung cho mọi benchmark.
- Các công ty có thể **tùy chỉnh cách đo lường** (phần cứng, kỹ thuật tối ưu hóa, v.v.), làm cho kết quả khó so sánh trực tiếp.

🔴 2. Phạm vi đánh giá hạn chế

- Nhiều benchmarks sử dụng **câu hỏi trắc nghiệm**, khiến mô hình có thể đạt điểm cao nhưng chưa chắc thể hiện được **khả năng suy luận sâu sắc**.

🔴 3. Nguy cơ rò rỉ dữ liệu huấn luyện

- Khó đảm bảo rằng câu trả lời của mô hình không bị ảnh hưởng bởi dữ liệu đã được dùng trong quá trình huấn luyện.
- Càng nhiều dữ liệu huấn luyện, nguy cơ này càng tăng.

🔴 4. Hiện tượng overfitting (quá khớp)

- Mô hình có thể được **tối ưu hóa quá mức** cho các bài test, làm cho nó đạt điểm cao nhưng **không thực sự thông minh**.
- Nếu thay đổi cách đặt câu hỏi nhưng cùng kiểm tra một kỹ năng, mô hình có thể **thất bại hoàn toàn**.

🔴 5. Khả năng "nhận thức" khi bị đánh giá

- Một số mô hình tiên tiến (GPT-4, Claude 3.5, v.v.) có thể **nhận ra chúng đang được đánh giá**, từ đó **thay đổi cách trả lời** để có vẻ đáng tin cậy hơn.
- Điều này có thể **bóp méo kết quả**, đặc biệt trong các bài test về **độ an toàn và tính trung thực**.



6 Hard, Next-Level Benchmarks

Benchmark	What's being evaluated	Description
GPQA	Graduate Tests	448 expert questions; non-PhD humans score 34% even with web access
BBHard	Future Capabilities	204 tasks believed beyond capabilities of LLMs (no longer!)
Math Lv 5	Math	High-school level math competition problems
IFEval	Difficult instructions	Like, "write more than 400 words" and "mention AI at least 3 times"
MuSR	Multistep Soft Reasoning	Logical deduction, such as analyzing 1,000 word murder mystery and answering: "Who has means, motive and opportunity?"
MMLU-PRO	Harder MMLU	A more advanced and cleaned up version of MMLU including choice of 10 answers instead of 4

1. Hạn chế của benchmark:


- Kết quả có thể khác nhau do cách đo lường, phạm vi hẹp, rò rỉ dữ liệu và quá khớp.
- Một số mô hình có thể "nhận ra" rằng chúng đang bị kiểm tra, làm sai lệch kết quả.

2. Các bài kiểm tra benchmark nâng cao:

- **GPQA:** Câu hỏi chuyên sâu, khó tìm thấy đáp án trên Google. Claude 3.5 Sonnet đạt 59.4%, gần bằng tiến sĩ.
- **BBH:** Câu hỏi khó, nhưng mô hình mới đã làm chủ.
- **MATH Level 5:** Câu đố toán học thử thách.
- **IFEval:** Kiểm tra khả năng làm theo hướng dẫn phức tạp.
- **MUSA:** Đánh giá suy luận logic qua vụ án giả tưởng.
- **MLU Pro:** Phiên bản nâng cao của bài kiểm tra hiểu ngôn ngữ.

Kết luận: Benchmark hữu ích nhưng không hoàn hảo, cần kết hợp nhiều phương pháp đánh giá.

4o



Hugging Face Open LM Leaderboard, một công cụ quan trọng để so sánh các mô hình mã nguồn mở dựa trên nhiều tiêu chí đánh giá. Trước tháng 6/2024, Hugging Face có một leaderboard cũ nhưng đã đóng để nhường chỗ cho phiên bản mới, giúp phân biệt rõ hơn giữa các mô hình khi chúng dần đạt hoặc vượt qua khả năng con người.

Leaderboard mới cho phép lọc theo loại mô hình (gốc, fine-tuned), kích thước tham số và độ chính xác. Các mô hình mạnh nhất hiện nay gồm **Qwen 2**, **Llama 3.1**, **Phi-3**, và **Yi**. Người dùng có thể khám phá các mô hình, kiểm tra hiệu suất theo từng tiêu chí như toán học, suy luận, hoặc hiểu ngôn ngữ.

Hugging Face khuyến khích các kỹ sư LM sử dụng leaderboard này thường xuyên để theo dõi và đánh giá mô hình.

