


Day 2

29 Tháng Ba 2025 5:47 CH



WEEK 4 DAY 2

Today equips you to make important decisions

What you can now do


- Code with Frontier Models including AI Assistants with Tools
- Build solutions with open-source LLMs with HuggingFace transformers
- Compare LLMs to identify the right one for the task at hand

After today you will be able to

- Navigate the most useful leaderboards and Arenas to evaluate LLMs
- Give real-world use cases of LLMs solving commercial problems
- Confidently choose LLMs for your projects

Bài giảng ngày thứ hai của tuần bốn tiếp tục đi sâu vào **leaderboards**, giúp bạn hiểu cách đánh giá và chọn LLM phù hợp.

Hôm nay, nội dung sẽ mở rộng từ **Hugging Face Open LLM Leaderboard** sang các **leaderboards** và **arenas** khác để so sánh mô hình. Ngoài ra, sẽ có phần thảo luận nhanh về **ứng dụng thực tế của LLM trong kinh doanh**, nhằm trang bị cho bạn kiến thức cần thiết để lựa chọn mô hình phù hợp cho từng nhiệm vụ.



Six Leaderboards

A tour of the essential leaderboards for selecting LLMs

		
HuggingFace Open LLM New and old version	HuggingFace BigCode	HuggingFace LLM Perf
		
HuggingFace Others eg Medical, Language-specific	Vellum includes API cost and context window	SEAL expert skills

1. **Hugging Face Open LLM Leaderboard** – Nền tảng so sánh mô hình mã nguồn mở với các chỉ số đánh giá khó hơn.
2. **Big Code Leaderboard** – Đánh giá các mô hình tạo mã lập trình.
3. **LM Perf Board** – Đánh giá hiệu suất mô hình, bao gồm độ chính xác, tốc độ và chi phí tính toán.
4. **Các bảng xếp hạng theo ngành và ngôn ngữ** – Ví dụ như bảng xếp hạng y tế, ngôn ngữ khác (Bồ Đào Nha,...).
5. **Valhalla Leaderboard** – So sánh cả mô hình mã nguồn mở và đóng, cung cấp thông tin về chi phí API, độ dài context window.
6. **Seal Leaderboard** – Đánh giá kỹ năng chuyên môn của các mô hình, liên tục cập nhật thêm tiêu chí mới.


Ngoài ra, bài giảng cũng giới thiệu về **Chatbot Arena**, một nền tảng đánh giá chatbot dựa trên LLM.

The Arena

The LMSYS Chatbot Arena is an amazing resource

- Compare Frontier and Open-source models directly
- Blind human evals based on head-to-head comparison
- LLMs are measured with an ELO rating

Participate in the voting - it's a terrific way to learn about different models while adding to the ecosystem



- **Chatbot Arena**
- Đánh giá mô hình trong ngữ cảnh hội thoại (chatbot).
- Con người sẽ trực tiếp so sánh hai mô hình trong một bài chat mà không biết danh tính mô hình.
- Kết quả dựa trên **đánh giá chủ quan**, mô hình sẽ nhận **điểm Elo** dựa trên mức độ ưu tiên so với đối thủ.
- Người học sẽ **tham gia bỏ phiếu** để hiểu rõ cơ chế đánh giá.
- **Ứng dụng thực tế của LLMs**
- Lĩnh vực: **Luật, tuyển dụng, lập trình, y tế, giáo dục,...**
- LLMs **đang có tác động sâu rộng** trên nhiều ngành.
- Học viên sẽ **xem các ví dụ thực tế** để hiểu rõ hơn về cách ứng dụng mô hình.

Big Code Models Leaderboard

Inspired from the [Open LLM Leaderboard](#) and [Open LLM Perf Leaderboard](#), we compare performance of base multilingual code generation models on [HumanEval](#) benchmark and [MultiPL-E](#). We also measure throughput and provide information about the models. We only compare open pre-trained multilingual code models, that people can start from as base models for their trainings.

[Evaluation table](#)
[Performance Plot](#)
[About](#)
[Submit results](#)

See All Columns

Search for your model and press ENTER...

Filter model types


☐ all
 ☒ base
 ☐ instruction-tuned
 ☐ EXT external-evaluation

T	Model	Win Rate	humaneval-python	java	javascript	cpp
	CodeQwen1.5-7B	45.08	50.79	42.15	50.07	48.35
	CodeLlama-70b	43.21	52.44	44.72	56.52	49.69
EXT	DeepSeek-Coder-33b-base	42.75	52.45	43.77	51.28	51.22
	CodeLlama-70b-Python	42.33	55.49	45.96	56.52	49.69
	StarCoder2-15B	39.92	44.15	33.86	44.24	41.44
EXT	DeepSeek-Coder-7b-base	38.33	45.83	37.72	45.9	45.53
	CodeLlama-34b	37.65	45.11	40.19	41.66	41.11
	CodeLlama-34b-Python	36.81	53.29	39.46	44.72	39.11
	CodeGemma-7B	33.83	40.13	35.03	43.06	40.34

Big Code Models Leaderboard (Xếp hạng mô hình lập trình)

- Chạy trên Hugging Face Spaces.
- Đánh giá các mô hình tạo mã (code generation) qua các bài kiểm tra trên **Python, Java, JavaScript, C++**.
- Điểm tổng hợp từ nhiều bài kiểm tra khác nhau.
- **Các mô hình hàng đầu:**
- **Code Queen** (chuyên về lập trình).
- **Code Llama** (mô hình của Meta).
- **DeepSeek Coder, StarCoder 2, CodeGemma** (mô hình mã nguồn mở của Google).
- **Ứng dụng:** Nếu bạn làm việc với AI lập trình, đây là bảng xếp hạng quan trọng để so sánh hiệu suất các mô hình.

LM Perf Leaderboard (Xếp hạng hiệu suất mô hình)



- **Đánh giá tốc độ, mức tiêu thụ bộ nhớ, năng lượng của các mô hình AI.**
- Biểu đồ trực quan hiển thị:
- **Tốc độ (x-axis):** Thời gian tạo 64 tokens.
- **Độ chính xác (y-axis):** Điểm tổng hợp của mô hình.
- **Bộ nhớ tiêu thụ (kích thước blob):** Blob càng lớn, bộ nhớ cần càng nhiều.
- **Màu sắc:** Thể hiện họ mô hình (Llama, Phi, Qwen,...).
- **Cách chọn mô hình tối ưu:**
- **Cần tốc độ cao:** Chọn mô hình lệch trái.
- **Cần độ chính xác cao:** Chọn mô hình trên cao.
- **Muốn tiết kiệm bộ nhớ:** Chọn blob nhỏ hơn.
- **Ví dụ:** Llama 3 và Qwen 1.5 có hiệu suất cao.
- **Ứng dụng:** Hữu ích khi tối ưu chi phí triển khai AI, đặc biệt khi chạy trên phần cứng giới hạn.

Big Code Models Leaderboard

Inspired from the [Open LLM Leaderboard](#) and [Open LLM Perf Leaderboard](#), we compare performance of base multilingual code generation models on [HumanEval](#) benchmark and [MultiPL-E](#). We also measure throughput and provide information about the models. We only compare open pre-trained multilingual code models, that people can start from as base models for their trainings.

Evaluation table | Performance Plot | About | Submit results

See All Columns

Search for your model and press ENTER...

Filter model types: ☐ all ☒ base ☐ instruction-tuned ☐ EXT external-evaluation



T	Model	Min Rate	humaneval-python	java	javascript	c++
	CodeQwen1.5-7B	45.08	50.79	42.15	50.07	48.35
	CodeLlama-70b	43.21	52.44	44.72	56.52	49.69
	EXT DeepSeek-Coder-33b-base	42.75	52.45	43.77	51.28	51.22
	CodeLlama-70b-Python	42.33	55.49	45.96	56.52	49.65
	StarCoder2-150	39.92	44.15	33.86	44.24	41.44
	EXT DeepSeek-Coder-7b-base	38.33	45.83	37.72	45.9	45.53
	CodeLlama-34b	37.65	45.11	40.19	41.66	39.9
	CodeLlama-34b-Python	36.81	53.29	39.46	44.72	39.9
	CodeGemma-7B	33.83	40.15	35.83	43.86	40.94

Các Bảng Xếp Hạng Khác

- Leaderboard theo ngôn ngữ:** Có bảng xếp hạng riêng cho Tiếng Bồ Đào Nha, Tiếng Tây Ban Nha, Tiếng Trung, v.v.
- Open Medical Leaderboard:**
- Đánh giá mô hình AI trong lĩnh vực y tế qua các bài kiểm tra **kiến thức y khoa, di truyền học, sinh học, PubMed QA**.
- Ứng dụng:** Nếu bạn phát triển mô hình AI trong ngành y tế, đây là nguồn tham khảo quan trọng.

Kết luận:

- Các leaderboards giúp lựa chọn mô hình AI phù hợp với từng mục tiêu cụ thể.
- Nếu bạn làm việc với mô hình lập trình, AI y tế, tối ưu hiệu suất, hãy sử dụng đúng leaderboard để đưa ra quyết định tốt nhất.




Tổng quan về Bảng Xếp Hạng Mô Hình Ngôn Ngữ (Leaderboard Fest)

Bài học tập trung vào việc phân tích và so sánh các mô hình ngôn ngữ mở và đóng trên các bảng xếp hạng hàng đầu ngoài Hugging Face.

1. Giới thiệu về Vellum Leaderboard

- Vellum AI** cung cấp một nguồn tài nguyên quan trọng cho những người làm việc với mô hình ngôn ngữ.
- Cung cấp bảng so sánh các mô hình dựa trên các tiêu chí như lý luận (MLU), lập trình (HumanEval), toán học, tốc độ, độ trễ và chi phí.
- Một số phát hiện quan trọng:**
- GPT-4o dẫn đầu về lý luận.
- Llama 3 405B là mô hình mã nguồn mở mạnh mẽ, cạnh tranh với các mô hình đóng.
- Claude 3.5 Sonnet vượt trội trong lập trình.
- Mô hình nhỏ hơn thường có tốc độ nhanh hơn.



vellum

Model Comparison | Coding Benchmarks | Cost and Context Length

General | Reasoning | Coding | Math | Tool Use

Model Comparison

BBHard Benchmark

	Average	Multi-choice Qs	Reasoning	Python coding	Future Capabilities	Grade school math	Math Problems
Claude 3.5 Sonnet	88.38%	88.70%	89.00%	92.00%	93.10%	96.40%	71.10%
Claude 3 Opus	84.83%	86.80%	95.40%	84.90%	86.80%	95.00%	60.10%
Gemini 1.5 Pro	80.08%	81.90%	92.50%	71.90%	84%	91.70%	58.50%
Gemini Ultra	79.52%	83.70%	87.80%	74.40%	83.60%	94.40%	53.20%
GPT-4	78.45%	86.40%	95.30%	67%	83.10%	92%	52.90%
Llama 3 Instruct - 70B	79.23%	82%	87%	81.7%	81.3%	93%	50.4%
Claude 3 Haiku	73.08%	75.20%	85.90%	75.90%	73.70%	88.90%	38.90%
GPT-3.5	65.46%	70%	85.50%	48.10%	66.60%	57.10%	34.1%
Mixtral 8x7B	59.79%	70.60%	84.40%	40.20%	60.76%	74.40%	28.40%
GPT-4o	-	88.7%	-	90.2%	-	-	76.60%
GPT-4o mini	-	82%	-	87.00%	-	-	70.20%
Llama 3 Instruct - 8B	-	68.40%	-	62%	61%	79.60%	30%
Grok 1.5	-	73.00%	-	63%	-	62.90%	23.90%

2. Các tiêu chí đánh giá mô hình


- Tốc độ:** Mô hình càng nhỏ, tốc độ sinh token càng nhanh.
- Độ trễ:** Tính bằng thời gian nhận token đầu tiên, mô hình nhỏ hơn có độ trễ thấp hơn.
- Chi phí:** Được đo bằng đô la trên mỗi triệu token, các mô hình nguồn mở như Llama thường có chi phí thấp hơn.
- Kích thước ngữ cảnh:**
 - Gemini 1.5 Flash có kích thước ngữ cảnh lên đến 1 triệu token.
 - GPT-4o hỗ trợ 128.000 token.
 - Mô hình nguồn mở như Llama thường giới hạn ở 8.000 token.

3. Giới thiệu về Scale Leaderboard

- Bảng xếp hạng từ Scale AI chuyên về đánh giá các mô hình theo các tiêu chí như:
 - Tính chịu lỗi với câu hỏi tấn công (Adversarial Robustness).**
 - Lập trình:** Claude 3.5 Sonnet dẫn đầu.
 - Tuân thủ hướng dẫn (Instruction Following):** Llama 3 405B đứng thứ hai, chỉ sau Claude 3.5 Sonnet.
 - Toán học:** Llama 3 405B đứng thứ ba.

News & Insights Latest News Topics Press Resources The 360 Blog

and then auto-populate an electronic referral form using natural language prompts, embedded within the flow of their work.



Einstein Copilot can generate interaction summaries for the care coordinator, which can be sent to the patient as well as any new primary care provider, and are easily added to records in the system. The call summary includes all details of the interaction as well as clearly-articulated next steps for the patient.

- Assessment Generation** will let healthcare organizations digitize standardized health assessments and automatically upload the information directly into [Salesforce Health Cloud](#). For example, an administrator can easily upload a form like an [OASIS-E](#) survey

Ứng dụng Thương mại của Mô hình Ngôn ngữ (LLMs)

Bài học giới thiệu 5 cách mà các mô hình ngôn ngữ lớn (LLMs) đang được sử dụng trong lĩnh vực thương mại. Khi xem xét các ứng dụng này, cần cân nhắc cách chọn mô hình phù hợp bằng cách sử dụng các bảng xếp hạng và tiêu chí đánh giá đã được đề cập trước đó.

1. Ứng dụng trong lĩnh vực pháp lý - Harvey AI

- Harvey** là một công ty sử dụng LLMs để hỗ trợ lĩnh vực pháp lý.
- Cung cấp các sản phẩm giúp luật sư trả lời câu hỏi pháp luật, tìm kiếm thuật ngữ quan trọng trong tài liệu pháp lý.
- Đây là một ứng dụng rất hợp lý, vì pháp luật đòi hỏi khả năng hiểu ngôn ngữ và phân tích sắc thái.

2. Ứng dụng trong tuyển dụng và nhân sự - Nebula IO

- Nebula IO** sử dụng LLMs để hỗ trợ tuyển dụng và quản lý nhân sự.
- Giúp nhà tuyển dụng tìm kiếm và tương tác với ứng viên phù hợp.
- Hỗ trợ cá nhân khám phá sự nghiệp phù hợp bằng cách phân tích nội dung và kinh nghiệm làm việc.

3. Ứng dụng trong chuyển đổi mã nguồn - Bloop AI

- Bloop AI** cung cấp nền tảng chuyển đổi mã nguồn cũ (COBOL, v.v.) sang Java.
- Giải quyết vấn đề bảo trì hệ thống cũ khi ngày càng ít lập trình viên sử dụng ngôn ngữ như COBOL.
- Ứng dụng LLMs để dịch mã nguồn, thêm chú thích và tạo test case tự động.