



Day 5


02 Tháng Tư 2025 7:12 CH



- Diễn giả không cần phải nói nhiều về sự hào hứng của người học vì chắc chắn họ đã cảm thấy rất phấn khích.
- Các kỹ năng đã học bao gồm:
 - Tạo và tinh chỉnh mô hình mở (open source models).
 - Sử dụng dữ liệu để xây dựng mô hình cơ bản và tinh chỉnh với Q Laura.
- Hôm nay, diễn giả sẽ giải thích rõ hơn về quá trình huấn luyện mô hình, điều mà trước đây đã được đề cập một cách mơ hồ. Đây là cơ hội để người học kết nối các điểm và hiểu rõ hơn về quá trình huấn luyện thực tế.
- Sau đó, sẽ thực hiện suy luận (inference) trên mô hình đã tinh chỉnh.
- Kết thúc tuần thứ bảy của khóa học, điều này rất thú vị và đánh dấu sự tiến bộ lớn.



1. **Forward Pass (Truyền qua mạng):** Dữ liệu được đưa vào mạng nơ-ron, qua đó mô hình đưa ra dự đoán về giá trị tiếp theo.
 2. **Loss Calculation (Tính toán mất mát):** Sau khi mô hình đưa ra dự đoán, mất mát được tính toán bằng cách so sánh kết quả dự đoán với giá trị thực tế.
 3. **Backward Pass (Truyền ngược - Backpropagation):** Dựa trên mất mát, quá trình truyền ngược tính toán các gradient (đạo hàm) của các trọng số trong mạng để xác định cách tối ưu hóa chúng.
 4. **Optimization (Tối ưu hóa):** Sử dụng các gradient tính được, các trọng số trong mạng sẽ được điều chỉnh nhẹ nhàng theo hướng giảm mất mát, nhằm cải thiện khả năng dự đoán trong các lần chạy tiếp theo.
- Quá trình huấn luyện này lặp lại nhiều lần qua các mini-batches và epochs để cải thiện mô hình.



Quá trình huấn luyện mô hình với Chullora bao gồm các bước sau:

1. **Forward Pass:** Dữ liệu được đưa vào mạng nơ-ron và mô hình dự đoán token tiếp theo (ví dụ: "price is dollars"). Các bộ điều chỉnh Lora được sử dụng để cải thiện việc dự đoán mà không thay đổi trọng số của mô hình cơ sở Llama 3.1.
2. **Loss Calculation:** Sau khi dự đoán token, mô hình so sánh kết quả dự đoán với giá trị thực tế từ dữ liệu huấn luyện và tính toán mất mát (loss), ví dụ, nếu mô hình dự đoán sai token, sẽ có một mất mát nhất định.
3. **Backward Pass (Backpropagation):** Trong bước này, mô hình tính toán các gradient, tức là sự thay đổi mất mát nếu trọng số trong mạng được điều chỉnh. Mục tiêu là xác định các trọng số cần điều chỉnh để giảm mất mát.
4. **Optimization:** Sau khi tính toán gradient, mô hình điều chỉnh các trọng số trong các bộ điều chỉnh Lora một cách nhỏ để cải thiện dự đoán trong các lần chạy tiếp theo. Quá trình này sử dụng tối ưu hóa Adam W để đảm bảo giảm mất mát và tránh hiện tượng overfitting.

Qua các bước này, mô hình dần dần học hỏi và cải thiện khả năng dự đoán, với các bộ điều chỉnh Lora được tinh chỉnh thay vì thay đổi mô hình cơ sở Llama 3.1 do kích thước quá lớn.

Next Token Prediction and Cross Entropy Loss

An important technical detail


The Model Output

- The model doesn't simply "Predict the next token"
- Rather, it outputs the probabilities of all possible next tokens
This is the result of using the 'softmax' function over the output from the last layer
- During inference, you can pick the token with highest probability, or sample from possible next tokens


The Loss Function

- The approach for calculating loss is quite simple:
 - Just ask: what probability did the model assign to the token that actually was the correct next token?
 - In practice we then take the log of this probability and times by -1
 - So 0 means we were 100% confident of the right result; higher numbers mean lower confidence
- This is called **cross-entropy loss**

- Thay vì dự đoán một token duy nhất, mô hình xuất ra xác suất cho tất cả các token có thể là tiếp theo. Những xác suất này được tạo ra bởi lớp cuối cùng của mô hình và được chuyển đổi thành xác suất thực tế qua hàm **softmax**.
- Khi chạy mô hình, ta chọn token có xác suất cao nhất làm token tiếp theo. Tuy nhiên, có thể sử dụng các kỹ thuật khác như lấy mẫu ngẫu nhiên để tạo ra sự đa dạng.
- Video cũng giải thích về **hàm mất mát (cross-entropy loss)**, dùng để đo mức độ sai lệch giữa dự đoán và kết quả đúng. Nếu xác suất của token đúng là 100%, hàm mất mát sẽ bằng 0, ngược lại, hàm mất mát sẽ tăng lên nếu xác suất thấp hơn.
- Cuối cùng, video kết luận rằng dự đoán token tiếp theo là một bài toán phân loại, và trong dự án của họ, dù là bài toán hồi quy (dự đoán giá trị số), họ xử lý như một bài toán phân loại với các bucket từ 1 đến 999.



- **Colab và Quá trình Huấn luyện:** Người dùng đang theo dõi mô hình đang huấn luyện trên Colab, với các epoch được chạy qua. Mặc dù chỉ cần một epoch, video đề cập đến việc huấn luyện qua bốn epoch.
- **Weights & Biases (W&B):** Cung cấp cái nhìn tổng quan về các chạy (runs) và theo dõi quá trình huấn luyện. Các chạy được đặt tên theo thời gian và có thể dễ dàng theo dõi qua W&B, nơi người dùng có thể xem các thông số và mô hình học.
- **Mất mát và Đánh giá:** Video đề cập đến biểu đồ "training loss", sử dụng hàm mất mát cross-entropy. Mặc dù không có bộ dữ liệu xác thực, người dùng cũng có thể xem khả năng mô hình bị overfitting khi so sánh các chạy.
- **So sánh các Chạy:** Khi so sánh các lần chạy khác nhau, kết quả huấn luyện rất giống nhau, chứng tỏ rằng các tham số (hyperparameters) được thiết lập ổn định và chính xác.
- **Học Tốc Độ và Sử Dụng Scheduler:** Video chỉ ra cách học tốc độ giảm dần nhờ vào "cosine learning rate scheduler", giúp điều chỉnh tốc độ học trong suốt quá trình huấn luyện.
- **Hugging Face:** Cuối video, mô hình được tải lên Hugging Face Hub để theo dõi và quản lý các phiên bản mô hình. Người dùng có thể thấy các tệp và phiên bản khác nhau của mô hình trên Hub và tải xuống các phiên bản cụ thể để thực hiện suy luận (inference).



- **Các mô hình đã thử:**
- **Mô hình hằng số:** Dự đoán giá trị trung bình của dữ liệu huấn luyện, với lỗi là 146.
- **Mô hình học máy đơn giản:** Sử dụng các tính năng cơ bản, có lỗi 139.
- **Random Forest:** Một thuật toán phức tạp hơn, với lỗi giảm xuống 97.
- **Con người:** Mô hình dự đoán của con người có lỗi 127.
- **GPT-4:** Mô hình mạnh mẽ này có lỗi 76.
- **Llama 3.1 (untrained):** Llama 3.1 chưa được huấn luyện, chỉ sử dụng 4 bit và có lỗi rất cao là 396.
- **Tổng quan về mô hình:**
- **GPT-4** có 1.76 triệu tỷ tham số, một mô hình cực kỳ mạnh mẽ.
- **Llama 3.1 base** có 8 tỷ tham số và được giảm xuống 4 bit, kết hợp với **Lora adapters** để điều chỉnh.
- **Lora adapters** bổ sung thêm 109MB tham số để tùy chỉnh mô hình.
- **Mục tiêu:**
- Mặc dù **Llama 3.1 base** là một mô hình mã nguồn mở, việc cạnh tranh với các mô hình tiên tiến như GPT-4 là rất khó khăn. Tuy nhiên, mục tiêu là so sánh với các mô hình học máy truyền thống, con người và mô hình hằng số để xem có thể cải thiện không.



1. So sánh hiệu suất mô hình

- Bắt đầu với mô hình đơn giản (sai số \$1.46).
- Thử nghiệm mô hình machine learning cơ bản (giảm còn \$1.39).
- Mô hình truyền thống tốt nhất đạt \$0.97.
- GPT-4 đạt \$0.76, con người đạt \$1.27.
- Mô hình tinh chỉnh tốt nhất hiện tại đạt \$0.47.

2. Cách cải thiện mô hình

- Tối ưu siêu tham số:** thử nghiệm tốc độ học, batch size, thuật toán tối ưu.
- Cải thiện suy luận (inference):** thay đổi cách chạy mô hình để có kết quả tốt hơn.
- Tối ưu dữ liệu:** kiểm tra lại dữ liệu đầu vào, cách thu thập và tổ chức dữ liệu.

3. Khuyến khích thử nghiệm mô hình khác

- Thử các mô hình như Jama, Kwon, Fi3.
- Kiểm tra LLaMA 3 với các mức bit khác nhau.
- Thử nghiệm với mô hình lớn hơn như Fi3 14B tham số.

4. Thử thách: Giảm sai số xuống dưới \$0.40

- Kêu gọi người tham gia cải thiện mô hình để đạt kết quả tốt hơn.
- Người đầu tiên đạt mục tiêu được khuyến khích chia sẻ cách làm để tái tạo kết quả.

Tóm tắt nội dung học được

Bài giảng này tổng kết tuần 7 và chuẩn bị cho tuần cuối cùng của khóa học.

1. Những kỹ năng đã học được sau tuần 7:

- Tạo văn bản và mã nguồn bằng **Frontier APIs**, **mô hình mã nguồn mở**, và **Hugging Face**.
- Giải quyết các bài toán như **thu thập và xử lý dữ liệu**, xây dựng **mô hình cơ bản**, và **tinh chỉnh mô hình**.

- Thành thạo quy trình **chọn và huấn luyện mô hình mã nguồn mở** để đạt hiệu suất vượt trội.

2. Kế hoạch cho tuần cuối:

- Triển khai mô hình ra môi trường sản xuất**, đóng gói vào API để sử dụng thực tế.
- Xây dựng một **ứng dụng hoàn chỉnh** từ mô hình đã huấn luyện.
- Mục tiêu cuối cùng là có thể tạo **giải pháp AI hoàn chỉnh cho vấn đề thực tế** bằng cách huấn luyện và triển khai LLM (mô hình ngôn ngữ lớn).

PROGRESS

I've kept the best to last

What you can now do

- Generate text and code with Frontier Models and Open Source models using APIs and HuggingFace, including tools, assistants and RAG
- Follow a 5 step strategy to solve problems, including dataset curation, making a baseline model, and fine-tuning a Frontier model
- Confidently carry out the end-to-end process for selecting and training specialized open source models that can outperform the Frontier

Next week is the finale - you will be able to

- Deploy customized models behind an API
- Create production products that use custom models
- Create an end-to-end solution to a commercial problem with groundbreaking LLMs

Udemy

