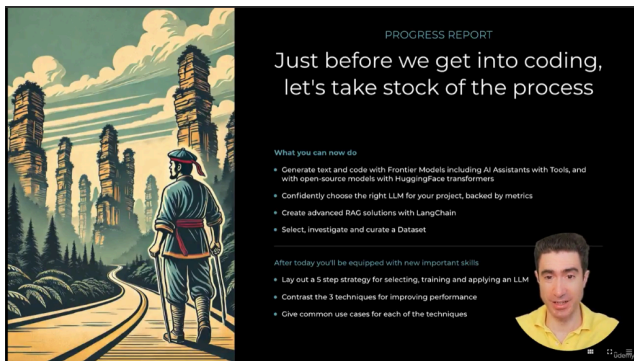




Tạo tập dữ liệu lớn:

- Sẽ quay lại làm việc với dữ liệu để xây dựng một tập dữ liệu lớn hơn.
- Tập dữ liệu này sẽ được sử dụng để huấn luyện mô hình và cải thiện hiệu suất.

Thảo luận về chiến lược:

- Phần lớn nội dung của buổi học sẽ là thảo luận về chiến lược.
- Nhấn mạnh tầm quan trọng của việc hiểu rõ chiến lược trước khi bắt đầu lập trình.

Quy trình giải quyết vấn đề kinh doanh:

- Thảo luận về quy trình chuyển đổi từ vấn đề kinh doanh sang giải pháp LLM (Language Model) trong môi trường sản xuất.
- Quy trình này sẽ được minh họa bằng ví dụ thực tế về vấn đề thương mại.


So sánh các kỹ thuật tối ưu hóa mô hình:

- So sánh ba kỹ thuật tối ưu hóa mô hình: prompting, Rag (Retrieval-Augmented Generation) và fine-tuning.
- Làm rõ sự khác biệt giữa các kỹ thuật và trường hợp sử dụng phù hợp cho từng kỹ thuật.
- Giải đáp những thắc mắc thường gặp về việc lựa chọn kỹ thuật tối ưu hóa.



Chiến lược 5 bước để áp dụng mô hình vào vấn đề thương mại:

- **Hiểu (Understand):**
 - Tìm hiểu sâu về yêu cầu kinh doanh.
 - Xác định vấn đề cần giải quyết.
 - Xác định tiêu chí đánh giá thành công.
 - Xem xét các yêu cầu phi chức năng (Non-functionals).
 - Ghi chép lại tất cả thông tin một cách cẩn thận.
- **Chuẩn bị (Prepare):**
 - Kiểm tra các mô hình cơ sở (baseline models).
 - Lựa chọn và chuẩn bị tập dữ liệu.
 - Chuẩn bị cho các bước tiếp theo.
- **Lựa chọn (Select):**
 - Chọn mô hình hoặc các mô hình sẽ được sử dụng trong dự án.
 - Sử dụng kiến thức từ các tuần học trước về bảng xếp hạng và phân tích ưu nhược điểm của các mô hình.
- **Tùy chỉnh (Customize):**
 - Sử dụng các kỹ thuật như Rag (Retrieval-Augmented Generation) hoặc tinh chỉnh (fine-tuning) để cải thiện hiệu suất mô hình.
- **Sản xuất hóa (Productionize):**
 - Khi mô hình đã được xây dựng, huấn luyện và hoạt động tốt, thì cần đưa mô hình vào môi trường sản xuất.
 - Khác với môi trường jupyter notebook, cần thực hiện thêm nhiều bước để đưa mô hình vào sản xuất.




Bước 1: Hiểu (Understand):

- **Thu thập yêu cầu kinh doanh:** Xác định rõ vấn đề cần giải quyết và mục tiêu của dự án.
- **Xác định tiêu chí đánh giá hiệu suất:**
 - Không chỉ tập trung vào các chỉ số khoa học dữ liệu (data science metrics) mà còn phải hiểu rõ các chỉ số kinh doanh (business metrics).
 - Các chỉ số kinh doanh sẽ giúp người dùng và nhà tài trợ đánh giá mức độ thành công của dự án.
- **Hiểu dữ liệu:**
 - Phân tích số lượng, chất lượng và định dạng dữ liệu.
 - Hiểu rõ dữ liệu sẽ ảnh hưởng đến việc lựa chọn mô hình và phương pháp tiếp cận.
- **Xác định các yêu cầu phi chức năng (non-functional requirements):**
 - Ngân sách: Chi phí dự án.
 - Khả năng mở rộng (scalability): Khả năng xử lý lượng dữ liệu lớn.
 - Độ trễ (latency): Thời gian phản hồi của mô hình.
 - Thời gian đưa sản phẩm ra thị trường (time to market): Yêu cầu về thời gian hoàn thành dự án.
 - Nếu yêu cầu thời gian ngắn, nên sử dụng mô hình frontier thông qua API và giao diện người dùng như Gradio.

Mục tiêu:

- Hiểu rõ tầm quan trọng của việc thu thập và phân tích thông tin trước khi bắt đầu xây dựng mô hình.
- Nắm bắt các yếu tố cần xem xét trong giai đoạn "Hiểu" để đảm bảo dự án thành công.

2. Prepare



Activities:

- **Research existing / non-LLM solutions**
Potential baseline model
- **Compare relevant LLMs**
The basics, including context length, price and license
Benchmarks, Leaderboards and Arenas
Specialist scores for the task at hand
- **Curate data:** clean, preprocess and split

Bước 2: Chuẩn bị (Prepare):

- **Nghiên cứu các giải pháp hiện có (LLM hoặc không phải LLM):**
 - Tìm hiểu các giải pháp hiện tại để giải quyết vấn đề.
 - Đánh giá hiệu suất của các giải pháp này.
 - Xem xét cả các giải pháp không sử dụng khoa học dữ liệu (ví dụ: các quy tắc đơn giản) và các giải pháp khoa học dữ liệu truyền thống (ví dụ: hồi quy tuyến tính).
 - Sử dụng các giải pháp hiện có làm cơ sở (baseline) để so sánh với hiệu suất của mô hình LLM.
- **So sánh các LLM liên quan:**
 - Xem xét các yếu tố cơ bản như giá cả, độ dài ngữ cảnh, giấy phép sử dụng.
 - Phân tích các điểm chuẩn (benchmarks), bảng xếp hạng (leaderboards) và đấu trường (arenas).
 - Tìm kiếm các điểm số chuyên biệt cho nhiệm vụ cụ thể (ví dụ: bảng xếp hạng SEAL từ Scale.com).
- **Chuẩn bị dữ liệu:**
 - Làm sạch (clean) dữ liệu.
 - Tiền xử lý (preprocess) dữ liệu (phân tích cú pháp, v.v.).
 - Chia dữ liệu thành các tập huấn luyện (training), xác thực (validation) và kiểm tra (test).
 - Tập huấn luyện được sử dụng để huấn luyện mô hình.
 - Tập xác thực được sử dụng để điều chỉnh siêu tham số (hyperparameters).
 - Tập kiểm tra được sử dụng để đánh giá hiệu suất cuối cùng của mô hình.

Mục tiêu:

- Hiểu rõ các hoạt động cần thiết trong giai đoạn "Chuẩn bị" để đảm bảo thành công của dự án.
- Nắm bắt cách so sánh các LLM và chuẩn bị dữ liệu cho quá trình huấn luyện.
- Nhận thức được tầm quan trọng của việc thiết lập một cơ sở (baseline) và sử dụng các tập dữ liệu được chia tách đúng cách.

3. Select



Activities:

- Choose LLM(s)
- Experiment
- Train and validate with curated data

Bước 3: Lựa chọn (Select):

- **Chọn LLM (hoặc các LLM):** Dựa trên các tiêu chí đã xác định trước đó.
- **Thử nghiệm:** Tiến hành các thử nghiệm với các LLM đã chọn.
- **Huấn luyện và xác thực với dữ liệu đã được chuẩn bị:** Sử dụng dữ liệu đã được làm sạch, tiền xử lý và chia tách để huấn luyện và xác thực mô hình.
- **Lưu ý:**
 - Việc huấn luyện và xác thực mô hình chưa được thực hiện trong video này.
 - Nội dung về bước 4 (tối ưu hóa) sẽ được tiếp tục trong video tiếp theo.

Mục tiêu:

- Hiểu rõ các hoạt động cần thiết trong giai đoạn "Lựa chọn" để chọn được LLM phù hợp.
- Nhận thức được tầm quan trọng của việc thử nghiệm và huấn luyện mô hình với dữ liệu đã được chuẩn bị kỹ lưỡng.

4. Customize

Three techniques to optimize the performance of the model



Prompting
multi-shot, chaining and tools

RAG

Fine-tuning

Bước 4: Tùy chỉnh (Customize):

- Tối ưu hóa mô hình để giải quyết vấn đề một cách hiệu quả hơn.
- Cải thiện mô hình đã được huấn luyện trước đó (pre-trained model) hoặc mô hình frontier hiện có.
- **Ba kỹ thuật tối ưu hóa mô hình:**
- **Prompting:**
 - Sử dụng các kỹ thuật như multi-shot prompting, chaining (kết hợp nhiều prompt) và sử dụng công cụ.
 - Đây là những cách để cải thiện kết quả đầu ra của mô hình.
- **Rag (Retrieval-Augmented Generation):**
 - Tích hợp thông tin từ bên ngoài vào quá trình tạo văn bản của mô hình.
- **Fine-tuning:**
 - Huấn luyện lại mô hình với dữ liệu cụ thể để cải thiện hiệu suất.

Sự khác biệt giữa các kỹ thuật:

- Prompting và Rag là các kỹ thuật tối ưu hóa tại thời điểm suy luận (inference time).
- Fine-tuning là kỹ thuật tối ưu hóa tại thời điểm huấn luyện (training time).
- Fine-tuning liên quan đến việc cung cấp thêm dữ liệu và điều chỉnh trọng số (weights) của mô hình.

Mục tiêu:

- Hiểu rõ các kỹ thuật tối ưu hóa mô hình.
- Nắm bắt sự khác biệt giữa các kỹ thuật và thời điểm sử dụng chúng.
- Chuẩn bị cho việc lựa chọn và áp dụng kỹ thuật tối ưu hóa phù hợp cho từng tình huống.

Three Techniques: Pros

Prompting

1. Fast to implement
2. Low cost
3. Often immediate improvement

RAG

1. Accuracy improvement with low data needs
2. Scalable
3. Efficient

Fine-tuning

1. Deep expertise & specialist knowledge
2. Nuance
3. Learn a different tone / style
4. Faster and cheaper inference

Three Techniques: Cons

Prompting

1. Limited by context length
2. Diminishing returns
3. Slower, more expensive inference

RAG

1. Harder to implement
2. Requires up-to-date, accurate data
3. Lacks nuance

Fine-tuning

1. Significant effort to implement
2. High data needs
3. Training cost
4. Risk of "catastrophic forgetting"

Three Techniques: Use Cases

PROMPTING

COT



Prompting

Often the starting point for optimizing a project with a Frontier LLM

RAG



RAG

You need high accuracy without the cost of fine-tuning; you have a knowledge base

FINE-TUNING



Fine-tuning

You have a specialized task with a high volume of data, and you need top performance

- Ưu điểm của Prompting:**
- **Triển khai nhanh:** Dễ dàng và nhanh chóng áp dụng các chiến lược prompting khác nhau.
 - **Chi phí thấp:** Không tốn kém nhiều tài nguyên để thực hiện.
 - **Cải thiện nhanh chóng:** Thường thấy sự cải thiện rõ rệt ngay sau khi áp dụng các kỹ thuật prompting.
- Ưu điểm của Rag (Retrieval-Augmented Generation):**
- **Cải thiện độ chính xác:** Cho phép trích xuất thông tin cụ thể để cung cấp cho LLM, giúp tăng độ chính xác.
 - **Khả năng mở rộng:** Có thể xử lý lượng lớn dữ liệu đầu vào.
 - **Hiệu quả:** Giảm chi phí so với việc cung cấp prompt lớn hơn.
- Ưu điểm của Fine-tuning:**
- **Xây dựng chuyên môn sâu:** Cho phép mô hình học các kỹ năng chuyên biệt và kiến thức sâu rộng.
 - **Sắc thái tinh tế:** Mô hình có thể hiểu và xử lý thông tin một cách tinh tế hơn.
 - **Học phong cách và giọng điệu khác nhau:** Mô hình có thể học cách mô phỏng phong cách và giọng điệu cụ thể.
 - **Suy luận nhanh hơn và rẻ hơn:** Sau khi được huấn luyện, mô hình có thể suy luận nhanh hơn và không cần tìm kiếm ngữ cảnh bên ngoài như Rag.


- Nhược điểm của Prompting:**
- **Giới hạn bởi độ dài ngữ cảnh:** Chỉ có thể đưa một lượng thông tin nhất định vào prompt.
 - **Hiệu quả giảm dần:** Khi đưa quá nhiều thông tin vào ngữ cảnh, hiệu quả học hỏi của mô hình giảm dần.
 - **Suy luận chậm hơn và tốn kém hơn:** Càng nhiều ngữ cảnh, suy luận càng chậm và tốn kém.
 - **Prompt chaining làm chậm quá trình xử lý.**
- Nhược điểm của Rag (Retrieval-Augmented Generation):**
- **Khó xây dựng hơn:** Yêu cầu cơ sở dữ liệu vector và duy trì cơ sở kiến thức.
 - **Yêu cầu dữ liệu cập nhật và chính xác:** Cơ sở kiến thức cần được cập nhật thường xuyên để đảm bảo tính chính xác.
 - **Thiếu sắc thái:** Khả năng học hỏi ý nghĩa sâu xa của dữ liệu hạn chế.
- Nhược điểm của Fine-tuning:**
- **Khó xây dựng hơn:** Yêu cầu nhiều công sức và thời gian.
 - **Yêu cầu dữ liệu lớn:** Cần nhiều ví dụ để huấn luyện mô hình.
 - **Chi phí huấn luyện cao:** Chi phí tính toán và tài nguyên để huấn luyện mô hình.
 - **Nguy cơ "quên thảm họa" (catastrophic forgetting):** Mô hình có thể quên thông tin cơ bản trong mô hình gốc khi được huấn luyện với dữ liệu mới.
- "Quên thảm họa" (catastrophic forgetting):**
- Hiện tượng mô hình quên thông tin cơ bản khi được huấn luyện với dữ liệu mới.
 - Cần cẩn thận nếu việc mất thông tin cơ bản ảnh hưởng đến hiệu suất.

- Trường hợp sử dụng Prompting:**
- Thường được dùng làm điểm khởi đầu cho một dự án.
 - Sử dụng để cải thiện hiệu suất của mô hình frontier ban đầu.
- Trường hợp sử dụng Rag (Retrieval-Augmented Generation):**
- Khi cần độ chính xác cao.
 - Khi không muốn tốn chi phí cho việc huấn luyện lại mô hình.
 - Khi có sẵn cơ sở kiến thức dữ liệu.
- Trường hợp sử dụng Fine-tuning:**
- Khi có nhiệm vụ chuyên biệt.
 - Khi có lượng dữ liệu lớn.
 - Khi cần hiệu suất cao nhất.
 - Khi cần mô hình có khả năng hiểu sắc thái.
- Ví dụ về dự án dự đoán giá sản phẩm:**
- Đây là một trường hợp phù hợp để sử dụng Fine-tuning vì:
 - Có lượng dữ liệu lớn.
 - Nhiệm vụ chuyên biệt.
 - Yêu cầu hiệu suất cao.
 - Cần khả năng hiểu sắc thái để phân biệt giá sản phẩm.
- Nội dung tiếp theo:**
- Tổng kết phân chiến lược.
 - Quay lại làm việc với dữ liệu và chuẩn bị dữ liệu.

5. Productionize

Activities:

- Determine API between model and platform(s)
- Identify model hosting and deployment architecture
- Address scaling, monitoring, security and compliance
- Measure the Business-Focused Metrics identified in step 1
- Continuously retrain and measure performance



Revisiting the 5 Step Strategy

In the context of the Business Problem



Understand
DONE



Prepare
IN PROGRESS



Select
TODO



Customize
TODO



Productionize
TODO



Bước 5: Sản xuất hóa (Productionize):


- Định nghĩa API:** Tạo API để gọi mô hình hoặc mã.
- Lựa chọn mô hình:** Sử dụng mô hình nguồn mở hoặc gọi mô hình frontier với các kỹ thuật như Rag hoặc prompt engineering.
- Triển khai và lưu trữ:** Quyết định cách lưu trữ và triển khai API.
- Giám sát và mở rộng:** Thiết lập hệ thống giám sát và đảm bảo khả năng mở rộng của mô hình.
- Đo lường và cải thiện:** Đo lường các chỉ số kinh doanh và liên tục cải thiện mô hình.

Tiến độ dự án dự đoán giá sản phẩm:

- Bước 1 (Hiểu):** Đã hoàn thành.
- Bước 2 (Chuẩn bị):** Đang thực hiện (chuẩn bị tập dữ liệu).
- Bước 3 (Lựa chọn):** Cần thực hiện.
- Bước 4 (Tùy chỉnh):** Cần thực hiện.
- Bước 5 (Sản xuất hóa):** Cần thực hiện.

Nội dung tiếp theo:

- Hoàn thành bước 2 (Chuẩn bị) bằng cách quay lại JupyterLab và tiếp tục chuẩn bị dữ liệu.



Giai đoạn 2 của tuyển chọn dữ liệu:

- Mở rộng tập dữ liệu để có phạm vi bao phủ lớn hơn.
- Tạo ra một tập dữ liệu phù hợp cho mục đích huấn luyện.

Mô-đun "loaders.py":

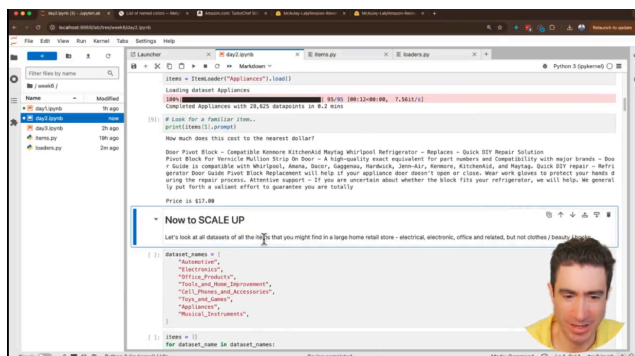
- Chứa một lớp có tên ItemLoader để tải dữ liệu từ kho lưu trữ Hugging Face.
- Sử dụng thư viện concurrent.futures để tải dữ liệu song song, giúp tăng tốc quá trình tải.
- Hàm load có tham số workers để xác định số lượng worker sử dụng.
- Hàm load_in_parallel sử dụng ProcessPoolExecutor để tạo các worker.
- Dữ liệu được chia thành các chunk 1000 phần tử và xử lý song song.
- Sử dụng lớp item từ mô-đun items.py để tạo các điểm dữ liệu.

Giới hạn phạm vi giá:

- Chỉ chọn các sản phẩm có giá từ 0,50 đô la đến 999,49 đô la.
- Loại bỏ các sản phẩm có giá quá cao để tránh làm sai lệch kết quả.
- Giúp giữ cho sai số trong phạm vi hợp lý và để đánh giá hiệu suất mô hình hơn.
- Giới hạn phạm vi giá cho phép tập trung vào các sản phẩm có giá trị phổ biến hơn.

Lưu ý:

- Mã trong mô-đun loaders.py có thể tái sử dụng cho các dự án khác.
- Cần xem xét kỹ lưỡng mã để hiểu cách hoạt động của nó.
- Có thể thử nghiệm với các phạm vi giá khác nhau để xem ảnh hưởng đến kết quả.



Tải dữ liệu bằng nhiều worker:

- Việc tải dữ liệu bằng 8 worker giúp tăng tốc độ xử lý lên đáng kể so với việc tải tuần tự.
- Thời gian tải dữ liệu "appliances" giảm từ khoảng 1 phút xuống còn 0.2 phút.
- Khuyến nghị sử dụng tham số workers để điều chỉnh số lượng worker phù hợp với khả năng của máy tính.

Kiểm tra dữ liệu đã tải:

- In ra phần tử đầu tiên của tập dữ liệu "appliances" để kiểm tra nội dung.
- In ra prompt của phần tử đầu tiên để kiểm tra xem các mã phụ tùng phức tạp đã được lọc bỏ hay chưa.

Xác nhận kết quả:

- Mã phụ tùng phức tạp đã được lọc bỏ thành công.
- Tập dữ liệu "appliances" chứa các sản phẩm gia dụng như bộ dụng cụ lắp ráp giá đỡ máy rửa bát và khối trực bản lề cửa.

Mở rộng tập dữ liệu:

- Tài thêm nhiều tập dữ liệu từ kho lưu trữ "Amazon Product Prices dataset".
- Chọn các tập dữ liệu có sản phẩm tương tự như trong một cửa hàng bán lẻ đồ gia dụng lớn.
- Loại trừ các tập dữ liệu về quần áo, mỹ phẩm, sách và phần mềm.

Các tập dữ liệu được chọn:

- Automotive (Ô tô)
- Electronics (Điện tử)
- Office Products (Văn phòng phẩm)
- Tools and Home Improvement (Dụng cụ và Cải thiện nhà cửa)
- Cell Phones and Accessories (Điện thoại di động và Phụ kiện)
- Toys and Games (Đồ chơi và Trò chơi)
- Appliances (Đồ gia dụng)
- Musical Instruments (Nhạc cụ)

Tùy chỉnh tập dữ liệu:



- Bạn có thể thay đổi danh sách các tập dữ liệu để thử nghiệm với các loại sản phẩm khác nhau.
- Nếu muốn xử lý nhanh hơn, bạn có thể chỉ sử dụng một số tập dữ liệu nhỏ hơn, ví dụ như "appliances" hoặc "electronics".

Tải dữ liệu bằng ItemLoader:

- Sử dụng ItemLoader để tải tất cả các tập dữ liệu đã chọn.
- Tập dữ liệu "automotive" là lớn nhất và sẽ được tải đầu tiên.
- Lần đầu chạy, quá trình tải sẽ mất nhiều thời gian hơn do phải tải dữ liệu từ Hugging Face về máy tính.

Thời gian tải dữ liệu:

- Tổng thời gian tải dữ liệu trên máy tính của người nói là khoảng 20 phút.
- CPU của máy tính hoạt động hết công suất trong quá trình tải.



Thời gian tải dữ liệu:

- Việc tải tất cả các tập dữ liệu mất khoảng 20 phút.
- Sau khi tải xong, các tập dữ liệu đã sẵn sàng để sử dụng.

Tổng quan về dữ liệu:


- Tập dữ liệu "automotive" là lớn nhất, chứa hơn 900.000 điểm dữ liệu.
- Tập dữ liệu "electronics" chứa hơn 400.000 điểm dữ liệu.
- Tổng số điểm dữ liệu là hơn 2,8 triệu.
- Số lượng dữ liệu này là quá lớn và có thể được tối ưu hóa để chọn ra những điểm dữ liệu có giá trị nhất.

Phân phối số lượng token:

- Biểu đồ phân phối số lượng token cho thấy không có prompt nào vượt quá 180 token.
- Điều này phù hợp với mục tiêu huấn luyện mô hình Llama và giảm chi phí khi sử dụng mô hình frontier.



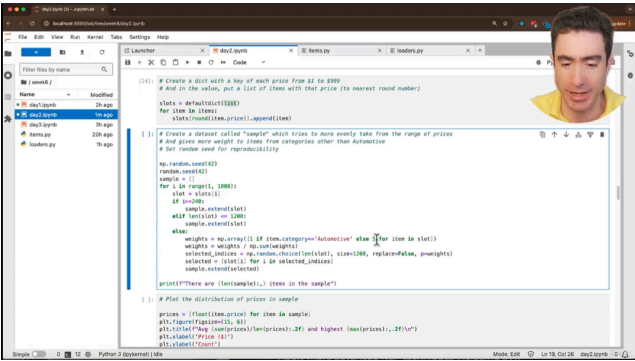
Phân phối giá:

- Phân phối giá cho thấy giá sản phẩm nằm trong khoảng từ 1 đến 999 đô la, theo giới hạn đã đặt.
- Dữ liệu bị lệch nhiều về phía giá thấp, với số lượng lớn sản phẩm có giá thấp.
- Số lượng sản phẩm có giá cao rất ít và khó nhìn thấy trên biểu đồ.



Phân phối dữ liệu theo danh mục:

- Một biểu đồ cột được hiển thị, cho thấy số lượng sản phẩm trong mỗi danh mục dữ liệu.
- Danh mục "Automotive" (Ô tô) có số lượng sản phẩm lớn nhất, với khoảng 900.000 sản phẩm.
- Tiếp theo là danh mục "Tools and Home Improvement" (Dụng cụ và Cải thiện nhà cửa).
- Danh mục "Electronics" (Điện tử) có khoảng 400.000 sản phẩm.



Cân bằng tập dữ liệu:

- Tập dữ liệu gốc có thể bị lệch, ảnh hưởng đến việc huấn luyện mô hình.
- Cần tạo một tập dữ liệu con (sample) cân bằng hơn về giá và danh mục sản phẩm.
- Mục tiêu là tạo ra một tập dữ liệu con khoảng 400.000 điểm dữ liệu.

Tạo từ điển "slots":

- Từ điển "slots" được tạo ra để nhóm các sản phẩm theo giá nguyên đô la của chúng.
- Khóa của từ điển là giá (từ 1 đến 999 đô la).
- Giá trị của từ điển là một danh sách các sản phẩm có giá tương ứng.
- Sử dụng defaultdict để tự động khởi tạo danh sách rỗng nếu khóa không tồn tại.

Lấy mẫu từ các "slots":

- Lặp qua từng "slots" và lấy mẫu dữ liệu từ đó.
- Đối với các sản phẩm có giá trên 240 đô la, lấy tất cả các sản phẩm trong "slot".
- Đối với các sản phẩm có giá dưới 240 đô la, lấy ngẫu nhiên 1200 sản phẩm từ "slot".
- Sử dụng hàm numpy.random.choice để lấy mẫu ngẫu nhiên.
- Sử dụng tham số "weights" trong numpy.random.choice để ưu tiên các sản phẩm trong danh mục "automotive" (trọng số 1) so với các danh mục khác (trọng số 5).

Tùy chỉnh quá trình lấy mẫu:

- Quá trình lấy mẫu có thể được tùy chỉnh để tạo ra các tập dữ liệu con khác nhau.
- Bạn có thể thay đổi ngưỡng giá (240 đô la), số lượng sản phẩm lấy mẫu (1200) và trọng số của các danh mục.
- Thử nghiệm với các cài đặt khác nhau để xem ảnh hưởng đến hiệu suất mô hình.

Kết quả:

- Tập dữ liệu con (sample) được tạo ra có khoảng 408.000 điểm dữ liệu.

Kích thước tập dữ liệu con (sample):

- Tập dữ liệu con được tạo ra có kích thước phù hợp với mục tiêu (khoảng 400.000 điểm dữ liệu).

Phân phối giá trong tập dữ liệu con:

- Phân phối giá trong tập dữ liệu con hợp lý hơn so với tập dữ liệu gốc.
- Vẫn có nhiều sản phẩm giá rẻ, nhưng số lượng tương đối đồng đều ở các mức giá rẻ.
- Có đủ số lượng sản phẩm giá cao để mô hình học hỏi.

Phân phối giá trong tập dữ liệu con (sample):

- Có một số mức giá phổ biến, chẳng hạn như \$399 và \$499, có số lượng sản phẩm cao hơn. Điều này phản ánh thực tế thị trường.
- Phân phối giá trong tập dữ liệu con được cải thiện đáng kể so với tập dữ liệu gốc, với sự cân bằng tốt hơn giữa các sản phẩm giá thấp và giá cao.
- Việc cân bằng này sẽ giúp mô hình học hỏi và đánh giá hiệu suất tốt hơn.
- Khuyến khích thử nghiệm với các tập dữ liệu khác nhau để so sánh hiệu suất mô hình.

Phân phối danh mục sản phẩm:


- Phân phối danh mục sản phẩm có sự thay đổi nhẹ so với tập dữ liệu gốc, nhưng vẫn giữ được sự phản ánh tương đối của thực tế thị trường.
- Danh mục "Automotive" (Ô tô) vẫn chiếm ưu thế, nhưng không quá lớn.
- Biểu đồ tròn được sử dụng để trực quan hóa phân phối danh mục, cho thấy "Automotive" chiếm phần lớn nhất, nhưng không áp đảo.
- "Appliances" là danh mục có phần trăm thấp nhất.

Tuyển chọn tập dữ liệu:

- Quá trình tuyển chọn tập dữ liệu đòi hỏi nhiều công sức, đặc biệt là phần lấy mẫu.
- Người xem được khuyến khích xem xét kỹ lưỡng và đánh giá lại quá trình lấy mẫu, cũng như thử nghiệm với các cách tạo tập dữ liệu khác nhau.

Phân tích cuối cùng và tải lên Hub:

- Tập dữ liệu sẽ được phân tích lần cuối trước khi tải lên Hub.
- Phân tích cuối cùng sẽ được thực hiện trong video tiếp theo.



Phân phối giá cả:

- Có một số mức giá phổ biến, như 399 đô la và 499 đô la, có số lượng sản phẩm cao hơn. Điều này phản ánh xu hướng giá cả trong thế giới thực.
- Phân phối giá cả trong tập dữ liệu đã được cải thiện so với trước đó, với sự cân bằng tốt hơn giữa các sản phẩm giá cao và giá thấp.
- Sự cải thiện này sẽ giúp mô hình học và đánh giá dữ liệu tốt hơn.
- Người xem được khuyến khích thử nghiệm với các tập dữ liệu khác nhau để so sánh hiệu suất.

Phân phối danh mục sản phẩm:

- Phân phối danh mục sản phẩm có sự thay đổi nhẹ, nhưng vẫn phản ánh sự phân bố tương đối của các sản phẩm trên thị trường.
- Danh mục "Automotive" (Ô tô) vẫn chiếm ưu thế, nhưng không quá lớn.
- Biểu đồ tròn được sử dụng để minh họa phân phối danh mục, cho thấy "Automotive" chiếm phần lớn nhất, nhưng không áp đảo.
- "Appliances" là danh mục có phần trăm thấp nhất.

Tuyển chọn tập dữ liệu:

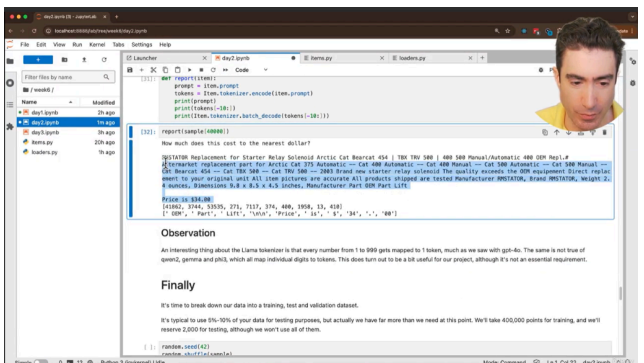
- Quá trình tuyển chọn tập dữ liệu đòi hỏi nhiều công sức, đặc biệt là phần lấy mẫu.
- Người xem được khuyến khích xem xét và đánh giá lại quá trình lấy mẫu, cũng như thử nghiệm với các cách tạo tập dữ liệu khác nhau.

Phân tích cuối cùng và tải lên Hub:

- Tập dữ liệu sẽ được phân tích lần cuối trước khi tải lên Hub.
- Phân tích cuối cùng sẽ được thực hiện trong video tiếp theo.

Điểm chính:

- Tập dữ liệu đã được tinh chỉnh để phản ánh tốt hơn sự phân phối giá và danh mục sản phẩm trong thực tế.
- Quá trình này đòi hỏi sự cân nhắc cẩn thận và thử nghiệm.
- Phân tích cuối cùng sẽ được thực hiện trước khi tải dữ liệu lên Hub.



Tokenization và Llama Tokenizer:


- Người nói giải thích về quá trình tokenization, đặc biệt là cách Llama tokenizer hoạt động.
- Hàm report được tạo ra để in ra prompt, 10 token cuối cùng và giải mã chúng.
- Llama tokenizer có một đặc điểm là nó ánh xạ mỗi số từ 1 đến 999 thành một token riêng biệt.
- Điều này khác với các tokenizer của các mô hình khác như GPT, Gemma và Phi-3.

Ví dụ về Tokenization:

- Người nói chạy hàm report với các mục dữ liệu ngẫu nhiên để minh họa cách tokenization hoạt động.
- Ví dụ cho thấy rằng "price", "is", "dollars" và số tiền (ví dụ: 34, 9, 765) được ánh xạ thành các token riêng biệt.
- Điều này giúp đơn giản hóa một số bước xử lý sau này trong dự án.

Sự khác biệt giữa các Tokenizer:

- Người nói nhấn mạnh rằng các tokenizer khác nhau có thể xử lý các số theo cách khác nhau.
- Trong khi Llama tokenizer ánh xạ mỗi số từ 1 đến 999 thành một token, các tokenizer khác có thể chia số thành nhiều token.
- Người nói lưu ý rằng việc sử dụng các mô hình khác như Gemma hoặc Phi-3 vẫn khả thi, nhưng sẽ dẫn đến việc số được chia thành nhiều tokens.



Chuẩn bị dữ liệu để tải lên Hub:

- Bước cuối cùng là hoàn thiện và tải dữ liệu lên Hub.
- Dữ liệu cần được xáo trộn để đảm bảo tính ngẫu nhiên, tránh việc mô hình học theo thứ tự giá cả.
- Sử dụng `random . seed` để đảm bảo tính nhất quán và khả năng tái tạo kết quả.
- Sử dụng `random . shuffle` để xáo trộn dữ liệu.

Chia dữ liệu thành tập huấn luyện và tập kiểm tra:

- Lấy 400.000 điểm dữ liệu đầu tiên làm tập huấn luyện.
- Lấy 2.000 điểm dữ liệu tiếp theo làm tập kiểm tra.
- Lưu ý rằng kích thước tập kiểm tra nhỏ hơn so với thông lệ (thường là 5-10% tổng dữ liệu).
- Giải thích rằng kích thước này đủ cho mục đích của dự án, vì hiệu quả kiểm tra giảm dần khi tăng kích thước tập kiểm tra.
- Khuyến khích người xem có thể sử dụng kích thước tập kiểm tra lớn hơn nếu muốn.

Kiểm tra dữ liệu huấn luyện và kiểm tra:

- In ra prompt của phần tử đầu tiên trong tập huấn luyện, cho thấy prompt bao gồm mô tả sản phẩm và giá cả.
- In ra prompt của phần tử đầu tiên trong tập kiểm tra, cho thấy prompt chỉ bao gồm mô tả sản phẩm, không có giá cả.
- In ra biểu đồ phân phối giá của 250 điểm dữ liệu đầu tiên trong tập kiểm tra, cho thấy sự phân phối giá đa dạng.

Tạo và tải dữ liệu lên Hugging Face Hub:

- Mã được trình bày sẽ chuyển đổi dữ liệu huấn luyện và kiểm tra thành định dạng phù hợp để tải lên Hugging Face Hub.
- Sử dụng `Dataset.from_dict` để tạo đối tượng dataset từ danh sách prompt và giá.
- Sử dụng `dataset.push_to_hub` để tải dataset lên Hub.
- Người nói đã tải dữ liệu lên tài khoản Hugging Face Hub của họ.
- Bạn có thể tải dữ liệu từ tài khoản của người nói nếu không muốn thực hiện toàn bộ quá trình xử lý dữ liệu.

Lưu trữ dữ liệu bằng Pickle:

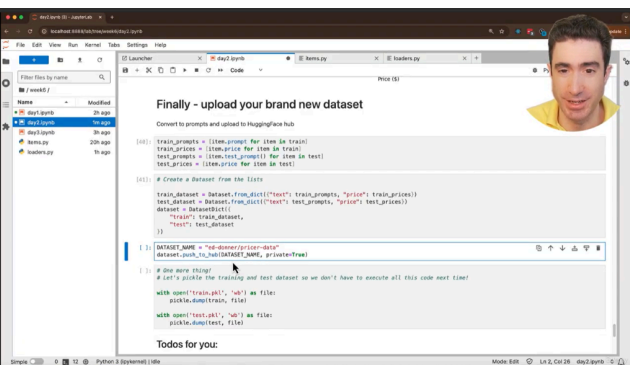
- Sử dụng `pickle` để lưu trữ dữ liệu huấn luyện và kiểm tra vào các file `train.pkl` và `test.pkl`.
- Điều này giúp tiết kiệm thời gian bằng cách tránh việc phải xử lý lại dữ liệu trong tương lai.


Hoàn thành quá trình xử lý dữ liệu:

- Quá trình xử lý dữ liệu đã hoàn tất.
- Người xem được khuyến khích khám phá dataset và thử nghiệm với quá trình tokenization.
- Đặc biệt, người xem nên xác nhận rằng các số có 3 chữ số được token hóa thành một token duy nhất.

Điểm chính:

- Dữ liệu đã được chuẩn bị và sẵn sàng để tải lên Hugging Face Hub.
- Sử dụng `pickle` để lưu trữ dữ liệu giúp tiết kiệm thời gian.
- Người xem nên khám phá dataset và thử nghiệm với quá trình tokenization.
- Người nói sẽ tóm tắt lại bài học trong slide tiếp theo.





Hoàn thành việc tạo và tải dữ liệu lên Hugging Face Hub:

- Người nói chúc mừng người xem đã hoàn thành việc tạo và tải lên một tập dữ liệu "pristine" lên Hugging Face Hub.
- Tập dữ liệu này đã được xử lý cẩn thận để đảm bảo có sự đại diện mẫu tốt cho việc huấn luyện mô hình.
- Người xem, nếu đã theo dõi và thực hành trên JupyterLab, sẽ có một tập dữ liệu riêng trên Hub để sử dụng trong các buổi học tiếp theo.

Các kỹ năng đã học được:

- Hiểu rõ chiến lược 5 bước để giải quyết các vấn đề kinh doanh thương mại bằng LLMs.
- Đánh giá ba kỹ thuật tối ưu hóa khác nhau.
- Nắm vững các chi tiết của việc tuyển chọn tập dữ liệu, bao gồm cả các đoạn mã phức tạp như lấy mẫu từ tập dữ liệu hiện có.

Nội dung học tập tiếp theo:

- Buổi học tiếp theo sẽ tập trung vào các mô hình cơ sở (baseline models).
- Người xem sẽ học cách tạo ra một giải pháp máy học truyền thống.
- Người xem sẽ được giới thiệu về các kỹ thuật truyền thống và nâng cao để đạt được kết quả tốt.

Sự mong đợi cho buổi học tiếp theo:

- Người nói bày tỏ sự hào hứng cho buổi học tiếp theo.

Điểm chính:

- Người xem đã hoàn thành việc tạo và tải dữ liệu lên Hugging Face Hub.
- Người xem đã học được các kỹ năng quan trọng liên quan đến LLMs và tuyển chọn dữ liệu.
- Buổi học tiếp theo sẽ tập trung vào các mô hình cơ sở và các kỹ thuật máy học.